

การตรวจจับการฉ้อโกงทางการเงิน ด้วยเทคนิคการเรียนรู้ของเครื่อง

Fraud Detection Using Machine Learning

พรเพชร สุขล้ำคณา¹, สงกรานต์ หนูน้อย¹, วรกฤต พ่อหลอน¹ และอนุพงศ์ สุขประเสริฐ^{2*}

¹สาขาธุรกิจดิจิทัลและระบบสารสนเทศ คณะการบัญชีและการจัดการ มหาวิทยาลัยมหาสารคาม

²อาจารย์ประจำคณะการบัญชีและการจัดการ มหาวิทยาลัยมหาสารคาม

Emails: 66010916009@msu.ac.th, 66010916021@msu.ac.th, 66010916047@msu.ac.th, anupong.s@msu.ac.th*

บทคัดย่อ

งานวิจัยนี้มีวัตถุประสงค์เพื่อสร้างแบบจำลองสำหรับตรวจจับธุรกรรมทางการเงินที่มีความเสี่ยงต่อการเป็น การฉ้อโกง โดยอาศัยชุดข้อมูลธุรกรรมทางการเงินของสถาบัน การเงินในประเทศสหรัฐอเมริกา ประกอบด้วย จำนวนเงิน ที่ทำธุรกรรม ประเภทของธุรกรรม ที่ตั้งภูมิศาสตร์ธุรกรรม ช่อง ทางการทำธุรกรรม อายุเจ้าของบัญชี ยอดคงเหลือหลัง ทำธุรกรรม และนำข้อมูลมาวิเคราะห์ตามกระบวนการ การวิเคราะห์ข้อมูล จากนั้นทำการประเมินประสิทธิภาพ ของแบบจำลอง เพื่อหาแบบจำลองที่มีแบบจำลอง ที่มีประสิทธิภาพสูงสุดสำหรับนำไปใช้ตรวจจับธุรกรรมทาง การเงินที่อาจเป็นการฉ้อโกง โดยใช้เทคนิคการเรียนรู้ของเครื่อง ได้แก่ เทคนิคต้นไม้ตัดสินใจ เทคนิคเพื่อนบ้านที่ใกล้ที่สุด และ เทคนิคต้นไม้ป่าสุ่ม

ผลการวิจัยพบว่าเทคนิคต้นไม้ตัดสินใจ มีความแม่นยำเท่ากับ 99.87% และค่าความเที่ยง เท่ากับ 99.89% ขณะที่ ค่าเรียกคืน เท่ากับ 99.85% ถือว่าเป็นแบบจำลอง ที่มีประสิทธิภาพสูงสุด ผลลัพธ์ดังกล่าวแสดงให้เห็นว่า แบบจำลองที่สร้างขึ้นมีศักยภาพในการนำไปประยุกต์ใช้เป็น เครื่องมือสนับสนุนการตัดสินใจในระบบตรวจสอบธุรกรรม ทางการเงินของธนาคาร เพื่อช่วยลดความเสี่ยงทางการเงิน เสริมสร้างความปลอดภัยของระบบการชำระเงิน และยกระดับ ความเชื่อมั่นของผู้ใช้บริการทางการเงินดิจิทัล ทั้งยังสามารถ นำไปต่อยอดเป็นแนวทางในการพัฒนาเทคโนโลยี ปัญญาประดิษฐ์เพื่อเพิ่มความมั่นคงทางการเงินในอนาคตได้ อย่างมีประสิทธิภาพ

คำสำคัญ : การตรวจจับการฉ้อโกง, การเงิน, การเรียนรู้ของ เครื่อง, ธุรกรรมธนาคาร

ABSTRACT

This study aims to develop a model for detecting potentially fraudulent financial transactions. Machine learning techniques were applied, including Decision Tree, K-Nearest Neighbors, and Random Forest algorithms. The dataset consists of seven key attributes: Transaction Amount, Transaction, Location, Channel, CustomerAge, and Account Balance, representing transaction characteristics and customer financial behavior.

The experimental results revealed that the Decision Tree model achieved the highest classification performance, with an accuracy of 99.87%, precision of 99.89%, and recall of 99.85%. These findings indicate that the proposed model can be effectively applied to banking transaction monitoring systems to reduce financial losses, enhance payment security, and strengthen customer trust in digital financial services. Moreover, the model provides a foundation for future research and development of artificial intelligence technologies aimed at improving financial system security and fraud prevention.

Keywords: Fraud Detection, Financial, Machine Learning, Bank Transactions

บทนำ

ในยุคดิจิทัลปัจจุบัน การทำธุรกรรมทางการเงินผ่านระบบออนไลน์มีอัตราการเติบโตอย่างรวดเร็วและกลายเป็นกิจกรรมทางเศรษฐกิจที่สำคัญในชีวิตประจำวัน ไม่ว่าจะเป็นการโอนเงิน ชำระค่าสินค้าและบริการหรือการลงทุน อย่างไรก็ตาม การเพิ่มขึ้นของธุรกรรมออนไลน์ได้นำมาซึ่งความเสี่ยงต่อการเกิดการฉ้อโกงทางการเงิน ซึ่งถือเป็นประเด็นเชิงความมั่นคงทางการเงินที่ส่งผลกระทบต่อผู้ใช้บริการและสถาบันการเงินในระดับโลก

ปัญหาดังกล่าวเกิดขึ้นจากหลายปัจจัย ทั้งช่องโหว่ด้านความปลอดภัยของระบบเทคโนโลยีสารสนเทศ การพัฒนาเทคนิคหลอกลวงที่มีความซับซ้อนมากขึ้นของผู้ไม่ประสงค์ดี รวมถึงพฤติกรรมของผู้ใช้บริการที่ขาดความระมัดระวัง นอกจากนี้ ปริมาณธุรกรรมที่เพิ่มขึ้นในระดับมหาศาลยังส่งผลให้วิธีการตรวจสอบการทุจริตแบบดั้งเดิม เช่น การตรวจสอบโดยเจ้าหน้าที่หรือระบบกฎเกณฑ์แบบตายตัว ไม่สามารถตอบสนองต่อการตรวจจับความผิดปกติได้อย่างมีประสิทธิภาพและทันทั่วถึง

ด้วยเหตุนี้ การประยุกต์ใช้เทคโนโลยีการวิเคราะห์ข้อมูลร่วมกับเทคนิคการเรียนรู้ของเครื่อง (Machine Learning) จึงได้รับความสนใจอย่างกว้างขวาง เนื่องจากสามารถวิเคราะห์รูปแบบพฤติกรรมของธุรกรรมทางการเงิน ระบุความผิดปกติ และตรวจจับธุรกรรมที่มีความเสี่ยงต่อการฉ้อโกงได้อย่างแม่นยำ การพัฒนาแบบจำลองและระบบอัจฉริยะในลักษณะดังกล่าวจึงมีบทบาทสำคัญต่อการยกระดับความปลอดภัย ลดความสูญเสียทางการเงิน และเสริมสร้างความเชื่อมั่นต่อระบบบริการทางการเงินดิจิทัลอย่างยั่งยืน

1. วัตถุประสงค์ของงานวิจัย

1.1 เพื่อสร้างแบบจำลองพยากรณ์ฉ้อโกงทางการเงินจากข้อมูลธุรกรรมของลูกค้า

1.2 เพื่อเปรียบเทียบประสิทธิภาพของแบบจำลองพยากรณ์ฉ้อโกงทางการเงินจากข้อมูลธุรกรรมของลูกค้า

2. เอกสารและงานวิจัยที่เกี่ยวข้อง

2.1 Khorasani [1] ได้เผยแพร่ชุดข้อมูล Bank Transaction Dataset for Fraud Detection บนเว็บไซต์ Kaggle ซึ่งเป็นข้อมูลธุรกรรมที่มีการกำหนดป้ายกำกับ (Label) ว่าธุรกรรมนั้นเป็น “ฉ้อโกง” หรือ “ไม่ฉ้อโกง” เพื่อใช้เป็นฐานข้อมูลสำหรับการพัฒนาแบบจำลองการตรวจจับด้วยเทคนิคการเรียนรู้ของเครื่อง ได้แก่ เทคนิคการจัดการถดถอย (Logistic Regression) เทคนิคต้นไม้ตัดสินใจ (Decision Tree) และ เทคนิคต้นไม้ป่าสุ่ม (Random Forest) ผลการวิเคราะห์พบว่าแบบจำลองที่สร้างด้วยเทคนิคต้นไม้ตัดสินใจ (Decision Tree) ให้ค่าความแม่นยำ (Accuracy) และค่าประสิทธิภาพโดยรวม (Measure) สูงกว่า 90% ซึ่งสามารถประยุกต์ใช้เป็นเครื่องมือช่วยในการตรวจจับธุรกรรมผิดปกติได้อย่างมีประสิทธิภาพ [1]

2.2 งานวิจัย FraudGuard: Bank Transactions Analysis [2] มุ่งเน้นการประยุกต์เทคนิคการเรียนรู้ของเครื่องเพื่อตรวจจับธุรกรรมที่ผิดปกติ โดยใช้ข้อมูลธุรกรรมธนาคารที่มีตัวแปรสำคัญ เช่น ประเภทธุรกรรม (Transaction Type), จำนวนเงิน (Amount), ยอดคงเหลือก่อน-หลัง (Old Balance, New Balance) และตัวบ่งชี้การฉ้อโกง (isFraud) งานวิจัยใช้เทคนิคต้นไม้ป่าสุ่ม (Random Forest) ซึ่งเป็นแบบจำลองแบบ Ensemble ที่รวมผลจากต้นไม้ตัดสินใจหลายต้นเพื่อเพิ่มความแม่นยำและเสถียรภาพในการทำนาย

ผลการทดลองให้ค่าความแม่นยำ (Accuracy) เท่ากับ 77% ซึ่งเพียงพอต่อการใช้งานจริงในขั้นตอนคัดกรอง (screening) ธุรกรรมที่มีความเสี่ยงสูง อีกทั้ง Random Forest ยังรับมือกับข้อมูลที่ซับซ้อนและมีความไม่สมดุลได้ดี โดยเฉพาะในกรณีธุรกรรมฉ้อโกงที่มีจำนวนน้อย

จุดเด่นของงาน FraudGuard คือ การใช้ฟีเจอร์เชิงพฤติกรรม เช่น ความถี่ของการทำธุรกรรมและยอดคงเหลือเฉลี่ย ช่วยให้แบบจำลองเข้าใจรูปแบบการฉ้อโกงได้แม่นยำยิ่งขึ้น [2]


2.3 Manorom et al. [3] ได้ทำการศึกษาเปรียบเทียบประสิทธิภาพของอัลกอริทึมการเรียนรู้ของเครื่อง 5 เทคนิค ได้แก่ เทคนิคต้นไม้ตัดสินใจ (Decision Tree) เทคนิคการจัดการถดถอย (Logistic Regression) เทคนิคเบย์อย่างง่าย (Naïve

Bayes) เทคนิคเพื่อนบ้านใกล้ที่สุด (K-Nearest Neighbor (K-NN)) และเทคนิคต้นไม้ป่าสุ่ม (Random Forest) เพื่อใช้ในการตรวจจับธุรกรรมทางการเงินที่เป็นการทุจริต โดยใช้ข้อมูลจากธุรกรรมบัตรเครดิตและเดบิตกว่า 19,000 รายการในสหรัฐอเมริกา

ผลการทดลองแสดงให้เห็นว่า เทคนิคเพื่อนบ้านใกล้ที่สุดและเทคนิคต้นไม้ป่าสุ่มให้ค่าความแม่นยำสูงสุด เท่ากับ 99.87% รองลงมาคือเทคนิคต้นไม้ตัดสินใจและเทคนิคการจัดการเชิงถดถอย เท่ากับ 99.86% และ 99.82% ตามลำดับ ขณะที่เทคนิคเบย์อย่างง่าย แม้มีค่าความแม่นยำต่ำสุด เท่ากับ 94.14% แต่สามารถตรวจจับธุรกรรมทุจริตได้บางส่วน ซึ่งชี้ให้เห็นถึงข้อจำกัดของการประเมินผลด้วยค่าความแม่นยำอย่างเดียว

วิธีการดำเนินการวิจัย

การตรวจจับธุรกรรมทางการเงินที่ผิดปกติควรใช้การประเมินหลายตัวชี้วัด เช่น ค่าความเที่ยง ค่าการเรียกคืน และค่าประสิทธิภาพโดยรวม เพื่อให้ได้ผลลัพธ์ที่แม่นยำมากขึ้น นอกจากนี้ ยังเน้นถึงปัญหาความไม่สมดุลของชุดข้อมูล (class imbalance) ซึ่งเป็นสาเหตุให้แบบจำลองบางประเภทมีค่าความแม่นยำสูงแต่ไม่สามารถระบุธุรกรรมทุจริตได้จริง [3]



ภาพ 1 กรอบแนวคิดการวิจัย (Conceptual Framework)

การดำเนินงานวิจัยสำหรับสร้างแบบจำลองและเปรียบเทียบประสิทธิภาพของแบบจำลองวิเคราะห์ชุดข้อมูลธุรกรรมธนาคารเพื่อการตรวจจับการฉ้อโกงทางการเงิน ผู้วิจัยได้วิเคราะห์ข้อมูลตามกระบวนการวิเคราะห์ข้อมูล โดยอ้างอิงกระบวนการมาตรฐานในการทำเหมืองข้อมูล (Cross-Industry Standard Process for Data Mining : CRISP-DM) [4] ซึ่งเป็นกระบวนการที่ใช้กันอย่างแพร่หลายในการพัฒนาแบบจำลองการวิเคราะห์ข้อมูล เพื่อให้การดำเนินงานเป็นไปอย่างมีระบบและเป็นมาตรฐานที่ยอมรับได้ การดำเนินการวิจัยสามารถสรุปได้เป็น 6 ขั้นตอนหลักดังนี้

1. การทำความเข้าใจปัญหา (Problem Understanding)

ปัจจุบันระบบธนาคารพาณิชย์ต้องเผชิญกับความท้าทายที่ใหญ่หลวงจากการเพิ่มขึ้นอย่างต่อเนื่องของการฉ้อโกงทางการเงินรูปแบบดิจิทัล ซึ่งมีความซับซ้อนและมีการปรับเปลี่ยนกลยุทธ์อย่างรวดเร็ว มูลค่าความเสียหายที่เกิดขึ้นจากการฉ้อโกงเหล่านี้มีได้จำกัดอยู่เพียงการสูญเสียทางการเงินโดยตรงต่อสถาบันเท่านั้น แต่ยังส่งผลกระทบต่อความน่าเชื่อถือ ความเชื่อมั่นของลูกค้า และการปฏิบัติตามกฎระเบียบ (Compliance) ที่เข้มงวดมากขึ้น

ผู้วิจัยได้ทำการวิเคราะห์บริบทของปัญหาธุรกรรมทางการเงินที่มีอัตราการฉ้อโกงเพิ่มสูงขึ้น รวมถึงลักษณะของธุรกรรมที่ผิดปกติซึ่งต้องการระบบตรวจจับที่รวดเร็วและแม่นยำ จากการพิจารณาดังกล่าว ผู้วิจัยจึงตั้งเป้าหมายในการพัฒนาแบบจำลองเพื่อจำแนกระดับความเสี่ยงของธุรกรรม พร้อมทั้งเปรียบเทียบประสิทธิภาพของเทคนิคการเรียนรู้ของเครื่องในการตรวจจับธุรกรรมที่มีแนวโน้มฉ้อโกง โดยมุ่งหมายให้แบบจำลองดังกล่าวสามารถนำไปประยุกต์ใช้จริงในระบบธนาคาร ความเข้าใจปัญหาอย่างรอบด้านในขั้นนี้จึงเป็นพื้นฐานสำคัญต่อการคัดเลือกข้อมูล การออกแบบแบบจำลอง และการประเมินผลในขั้นตอนถัดไป

2. การทำความเข้าใจเกี่ยวกับข้อมูล (Data Understanding)

งานวิจัยนี้ใช้ชุดข้อมูลธุรกรรมทางการเงินของธนาคารในสหรัฐอเมริกา โดยข้อมูลอ้างอิงปี 2024 เป็นข้อมูลจริงที่ได้จากเว็บไซต์ Kaggle [5] โดยมีรูปแบบไฟล์เป็น Excel เพื่อนำไปวิเคราะห์ในขั้นตอนต่อไป โดยมีทั้งหมด 2,512 แถว และตัวแปรหลักที่ใช้ 6 ตัวแปร ดังตาราง 1

ตาราง 1 ประมวลผลของแบบจำลอง Attribute ของข้อมูลธุรกรรม

No	Attribute	Data Type	Description
1	Transaction Amount	Real	จำนวนเงินที่ทำธุรกรรม
2	Transaction	Polynomial	ประเภทของธุรกรรม (เครดิต หรือ เดบิต)
3	Location	Polynomial	ที่ตั้งทางภูมิศาสตร์ ธุรกรรม
4	Channel	Polynomial	ช่องทางการทำธุรกรรม
5	CustomerAge	Integer	อายุเจ้าของบัญชี
6	Account Balance	Real	ยอดคงเหลือหลังทำธุรกรรม

3. การเตรียมข้อมูล (Data Preparation)

การเตรียมข้อมูลถือเป็นขั้นตอนวิกฤตที่ต้องดำเนินการอย่างพิถีพิถัน เพื่อเปลี่ยนชุดข้อมูลธุรกรรมทางการเงินดิบให้เป็นรูปแบบที่เหมาะสมและมีคุณภาพเพียงพอสำหรับการประมวลผลด้วยเทคนิคการเรียนรู้ของเครื่อง ซึ่งขั้นตอนนี้ส่งผลโดยตรงต่อความแม่นยำและความสามารถในการตรวจจับการฉ้อโกงของแบบจำลอง การดำเนินการในส่วนนี้แบ่งออกเป็น 2 ขั้นตอนหลัก

3.1 การคัดเลือกตัวแปร (Attribute Selection)

การคัดเลือกตัวแปรที่มีนัยสำคัญทางสถิติต่อการวิเคราะห์ธุรกรรมและการระบุรูปแบบการฉ้อโกง โดยเน้นเฉพาะคุณลักษณะหลักเพื่อลดมิติของข้อมูล (Dimensionality Reduction) และเพิ่มความรวดเร็วในการประมวลผลของแบบจำลอง จากชุดข้อมูล Bank Transaction Dataset for Fraud Detection ซึ่งเผยแพร่บนเว็บไซต์ Kaggle ผู้วิจัยได้คัดเลือกตัวแปรจำนวน 6 ตัวแปร เพื่อใช้ในการวิเคราะห์และการสร้างแบบจำลอง ได้แก่ จำนวนเงินที่ทำธุรกรรม (Transaction Amount) ประเภทของธุรกรรม (Transaction) ที่ตั้งทางภูมิศาสตร์ธุรกรรม (Transaction Location) ช่องทางการทำธุรกรรม (Channel) อายุเจ้าของบัญชี (CustomerAge) และยอดคงเหลือหลังทำธุรกรรม (Account Balance) โดยมีรายละเอียดและเหตุผลในการคัดเลือกตัวแปรดังนี้

1. จำนวนเงินที่ทำธุรกรรม (Transaction Amount) เป็นตัวแปรเชิงปริมาณหลักที่แสดง มูลค่าของธุรกรรมทางการเงิน ซึ่งมี

ความสัมพันธ์โดยตรงกับ การตรวจจับการฉ้อโกง เนื่องจากธุรกรรมทางการเงินที่มีมูลค่า สูงผิดปกติอาจบ่งชี้ถึงพฤติกรรมที่มีความเสี่ยง (Anomalous Behavior) [6] ดังนั้น ตัวแปรนี้จึงเป็นปัจจัยสำคัญในกระบวนการสร้างแบบจำลองเชิงพยากรณ์ (Predictive Modeling)

2. ประเภทของธุรกรรม (Transaction) ตัวแปรนี้ใช้ระบุประเภทของธุรกรรมทางการเงิน เช่น การฝาก ถอน หรือโอนเงิน ซึ่งช่วยให้สามารถ วิเคราะห์รูปแบบการทำธุรกรรมทางการเงินที่แตกต่างกันได้ โดยแต่ละประเภทอาจมีระดับความเสี่ยงไม่เท่ากัน [7] การนำข้อมูลนี้มาใช้ช่วยเพิ่มความสามารถของแบบจำลองในการจำแนกธุรกรรมทางการเงินที่ผิดปกติ

3. ที่ตั้งทางภูมิศาสตร์ (Location) เป็นตัวแปรที่แสดงสถานที่ที่เกิดธุรกรรมซึ่งช่วยให้สามารถตรวจจับความผิดปกติทางภูมิศาสตร์เช่นการทำธุรกรรมทางการเงินจากหลายพื้นที่ในช่วงเวลาสั้นๆหรือจากประเทศที่ไม่สอดคล้องกับพฤติกรรมปกติของลูกค้า [8] การใช้ข้อมูลเชิงพื้นที่ (Geolocation Data) จึงมีบทบาทสำคัญในการตรวจจับพฤติกรรมการฉ้อโกง

4. ช่องทางการทำธุรกรรม (Channel) ตัวแปรนี้แสดงถึงช่องทางการทำธุรกรรมทางการเงิน เช่น ATM, Mobile Banking หรือ Internet Banking ซึ่งแต่ละช่องทางมีระดับความปลอดภัยต่างกัน การวิเคราะห์ตัวแปรนี้ช่วยระบุได้ว่าช่องทางใดมีแนวโน้มเกิดการฉ้อโกงมากที่สุด [9]

5. อายุของเจ้าของบัญชี (CustomerAge) เป็นตัวแปรด้านประชากรศาสตร์ (Demographic Variable) ที่มีอิทธิพลต่อรูปแบบการทำธุรกรรมทางการเงิน เช่น กลุ่มวัยรุ่นมักทำธุรกรรมทางการเงินผ่านช่องทางออนไลน์ ขณะที่กลุ่มสูงอายุอาจนิยมทำธุรกรรมทางการเงินที่สาขา การพิจารณาปัจจัยนี้ช่วยให้สามารถวิเคราะห์พฤติกรรมทางการเงินตามกลุ่มอายุได้อย่างมีประสิทธิภาพ [10]


6. ยอดคงเหลือหลังทำธุรกรรม (Account Balance) เป็นตัวแปรที่แสดงยอดเงินคงเหลือในบัญชีซึ่งสามารถใช้ตรวจสอบความสอดคล้องระหว่างมูลค่าธุรกรรมกับศักยภาพทางการเงินของลูกค้าหากมูลค่า ธุรกรรมสูงสัดส่วนกับยอดคงเหลืออาจบ่งชี้ถึงความเสี่ยงในการฉ้อโกง [11]

โดยสรุป การคัดเลือกตัวแปรทั้ง 6 ตัวนี้มีจุดมุ่งหมายเพื่อให้การวิเคราะห์สามารถสะท้อนพฤติกรรมทางการเงินของ

ลูกค้าได้รอบด้าน ทั้งด้านมูลค่าทางธุรกรรม ช่องทางการใช้บริการ และคุณลักษณะส่วนบุคคล ซึ่งจะช่วยเพิ่มความแม่นยำของแบบจำลองในการตรวจจับธุรกรรมทางการเงินที่มีแนวโน้มเป็นการฉ้อโกงได้อย่างมีประสิทธิภาพ

3.2 การให้ป้ายกำกับ (Data Labeling)

ผู้วิจัยได้ทำการหาตัวแปรเป้าหมายของแบบจำลองด้วยการแบ่งกลุ่ม โดยใช้วิธี K-Means Clustering โดยการกำหนดจำนวนกลุ่ม (K) ที่เหมาะสมใช้วิธี Elbow Method โดยพิจารณาค่าระยะทางเฉลี่ยภายในกลุ่ม (Average Within-Cluster Distance) เปรียบเทียบกับค่าของ K หลายค่า เพื่อหาจุดที่ค่าระยะทางลดลงอย่างชัดเจนและเริ่มคงที่ ซึ่งเป็นจุดที่เรียกว่า “Elbow Point” ผลการวิเคราะห์พบว่า ค่า K ที่เหมาะสมที่สุดคือ 5 ดังแสดงในภาพที่ 2



ภาพ 2 การหาค่า K ในการแบ่งกลุ่มที่เหมาะสมที่สุดด้วยเทคนิค Elbow point

2. กลุ่มความเสี่ยงต่ำถึงปานกลาง (Low-Medium Risk) เป็นกลุ่มของธุรกรรมที่มีมูลค่าสูงกว่าเฉลี่ย แต่รูปแบบยังอยู่ในขอบเขตปกติ ไม่มีพฤติกรรมผิดปกติเด่นชัด

3. กลุ่มความเสี่ยงปานกลาง (Medium Risk) ประกอบด้วยธุรกรรมที่เกิดขึ้นบ่อยครั้งแต่มูลค่าไม่สูง ลักษณะดังกล่าวอาจบ่งชี้พฤติกรรมธุรกรรมซ้ำ ๆ

4. กลุ่มความเสี่ยงปานกลางถึงสูง (Medium-High Risk) เป็นกลุ่มขนาดปานกลางที่มีพฤติกรรมธุรกรรมแตกต่างจากรูปแบบทั่วไป อาจมีการเคลื่อนไหวทางการเงินที่ไม่สอดคล้องกับลักษณะของผู้ใช้

5. กลุ่มความเสี่ยงสูง (High Risk) เป็นกลุ่มที่มีจำนวนธุรกรรมน้อยที่สุด แต่มีลักษณะทางพฤติกรรมที่ผิดปกติและแตกต่างจากกลุ่มอื่นอย่างชัดเจน ถือเป็นกลุ่มที่มีแนวโน้มความเสี่ยงต่อการฉ้อโกงสูงสุด

การวิเคราะห์ดังกล่าวช่วยให้สามารถระบุลักษณะของกลุ่มข้อมูลที่แตกต่างกันตามระดับความเสี่ยงของธุรกรรมทางการเงินได้อย่างมีประสิทธิภาพ ผลลัพธ์จากการจัดกลุ่มนี้สามารถนำไปใช้เป็น ตัวแปรเป้าหมาย (Target Variable) สำหรับการสร้างแบบจำลองการจำแนกประเภทความเสี่ยงในขั้นตอนถัดไปของกระบวนการวิเคราะห์ข้อมูลเชิงพยากรณ์


3.3 การแปลงข้อมูลตัวแปรเชิงคุณภาพ

ผู้วิจัยได้ทำการแปลงข้อมูลเชิงคุณภาพให้เป็นข้อมูลเชิงปริมาณโดยใช้วิธี One-Hot Encoding ซึ่งเป็นวิธีมาตรฐานที่ช่วยให้แบบจำลองจำแนกประเภทสามารถประมวลผลตัวแปรเชิงหมวดหมู่ได้อย่างถูกต้อง โดยแทนค่าหมวดหมู่เป็นตัวเลข 0 และ 1

4. การสร้างแบบจำลอง (Modeling)


เมื่อข้อมูลถูกคัดเลือกตัวแปรและ แปลงให้อยู่ในรูปแบบข้อมูลที่มีโครงสร้างแล้ว ขั้นตอนต่อไปคือการสร้างแบบจำลองสำหรับการสร้างแบบจำลองเพื่อการตรวจจับการฉ้อโกงทางการเงิน โดยผู้วิจัยได้ใช้ 3 เทคนิค ประกอบด้วย เทคนิคต้นไม้ตัดสินใจ เทคนิคเพื่อนบ้านที่ใกล้ที่สุด และเทคนิคต้นไม้ป่าสุ่ม โดยใช้โปรแกรม Altair AI Studio version 2026 เพื่อสร้างแบบจำลองในครั้งนี้

4.1 เทคนิคต้นไม้ตัดสินใจ (Decision Tree) เป็นเทคนิคที่ใช้ในการแบ่งแยกข้อมูลโดยทำงานตามหลักการกฎเกณฑ์ (Rule-Based) ซึ่งมีลักษณะเป็นแผนผังคล้ายต้นไม้ ทำให้ตีความได้ง่าย (Interpretable) และเป็นรากฐานสำคัญของกลุ่มแบบจำลอง [12] เทคนิคนี้ถูกนำมาใช้อย่างแพร่หลายในการวิเคราะห์ธุรกรรมทางการเงินเพื่อจำแนกและพยากรณ์ความเสี่ยงของการฉ้อโกง




ภาพ 3 Decision Tree Algorithm [12]

4.2 เทคนิคเพื่อนบ้านใกล้ที่สุด (*k*-Nearest Neighbors : *k*-NN) เป็นเทคนิคที่ใช้ในการจัดแบ่งคลาสของข้อมูลโดยการเลือกคลาสที่จะแทนเงื่อนไขหรือกรณีใหม่ๆ โดยการพิจารณาจากจำนวนบางจำนวนของกรณีหรือเงื่อนไขที่มีความเหมือนหรือใกล้เคียงกันมากที่สุด [13] วิธีการนี้จะนับจำนวนเงื่อนไขและกำหนดค่า *K* ให้เป็นเลขคี่ แล้วคำนวณระยะห่างระหว่างข้อมูลที่ต้องการพิจารณากับกลุ่มข้อมูลตัวอย่าง เรียงลำดับระยะห่างและเลือกชุดข้อมูลที่ใกล้ที่สุดที่ต้องการพิจารณาตามจำนวน *K* ที่กำหนด จากนั้นจะพิจารณาข้อมูล *K* ชุด และกำหนดคลาสให้กับจุดที่พิจารณาซึ่งอยู่ใกล้จุดพิจารณามากที่สุด



ภาพ 4 k-Nearest Neighbors : k-NN Algorithm [13]

4.3 เทคนิคต้นไม้ป่าสุ่ม (*Random Forest*) เป็นการสร้างแบบจำลองทางสถิติและเป็นแบบจำลองประเภทหนึ่งของการเรียนรู้ของเครื่อง (*Machine Learning*) ซึ่งนำมาใช้กับข้อมูลที่มีหลายตัวแปร (*Multivariate*) หรือข้อมูลที่มีความซับซ้อนพัฒนาขึ้นจากเทคนิคต้นไม้ตัดสินใจโดยใช้หลักการมากกว่าหนึ่งคอลัมน์ได้ แต่ผู้เขียนต้องจัดวางให้อยู่กึ่งกลางของความกว้างของคอลัมน์ทั้งสองรวมกันของการแบ่งกลุ่ม ด้วยการรวมกันของข้อมูลหลายๆ ต้นไม้ตัดสินใจ [14]



ภาพ 5 Random Forest Tree Algorithm [14]

5. การประเมินผล (Evaluation)

ผู้วิจัยได้ทำการประเมินประสิทธิภาพแบบจำลองทั้ง 3 เทคนิคที่ใช้ในการจำแนกระดับความเสี่ยงของการฉ้อโกง โดยทำการแบ่งข้อมูลออกเป็นสองส่วน คือส่วนที่ใช้สำหรับการสร้างแบบจำลอง (*Training Set*) และส่วนที่ใช้สำหรับการทดสอบประสิทธิภาพของแบบจำลอง (*Testing Set*) โดยการใช้การตรวจสอบความถูกต้องแบบแบ่งส่วนข้อมูล (*Split Validation*) และการตรวจสอบความถูกต้องแบบไขว้ (*Cross Validation*) จากนั้นทำการประเมินประสิทธิภาพของแบบจำลองโดยใช้ตัวชี้วัด 4 ได้แก่

5.1 ตารางความสับสน (*confusion matrix*) คือตารางที่ใช้สรุปผลการทำนายของแบบจำลองการจำแนกประเภท (*Classification Model*) โดยเปรียบเทียบระหว่าง ค่าผลลัพธ์จริง (*Actual Class*) กับ ค่าที่แบบจำลองทำนาย (*Predicted Class*) เพื่อประเมินความถูกต้องและประสิทธิภาพของแบบจำลอง

5.2 ค่าความแม่นยำ (*Accuracy*) คือตัวชี้วัดที่แสดงสัดส่วนของจำนวนตัวอย่างที่แบบจำลองทำนายถูกต้องต่อจำนวนตัวอย่างทั้งหมด [15]

5.3 ค่าความเที่ยง (*Precision*) คือ ตัวชี้วัดที่แสดงสัดส่วนของจำนวนตัวอย่างที่แบบจำลองทำนายว่าเป็น “บวก” และทำนายถูกต้อง ต่อจำนวนตัวอย่างทั้งหมดที่แบบจำลองทำนายว่าเป็น “บวก” [15]

5.4 ค่าการเรียกคืน (*Recall*) คือ ตัวชี้วัดที่แสดงสัดส่วนของจำนวนตัวอย่างที่เป็น “บวกจริง” และแบบจำลองทำนายถูกต้อง ต่อจำนวนตัวอย่างบวกจริงทั้งหมด [15]

5.5 ประสิทธิภาพโดยรวม (*F-measure*) คือตัวชี้วัดที่สรุปความสมดุลระหว่างค่าความเที่ยง (*Precision*) และค่าการเรียกคืน (*Recall*) โดยเป็นค่าเฉลี่ยฮาร์โมนิกของทั้งสองค่า [15]

6. การนำไปใช้ (Deployment)

เมื่อดำเนินการเปรียบเทียบประสิทธิภาพของแบบจำลองเพื่อหาแบบจำลองที่เหมาะสมที่สุดแล้ว ผู้วิจัยจึงนำแบบจำลองที่ได้นี้ไปใช้สำหรับสร้างแบบจำลองที่สามารถนำไปประยุกต์ใช้ในระบบตรวจสอบธุรกรรมของธนาคารเพื่อช่วยลดความสูญเสียทางการเงินเพิ่มความปลอดภัยของระบบการชำระเงินและยกระดับความเชื่อมั่นของผู้ใช้บริการทางการเงิน ดิจิทัลทั้งยังสามารถต่อยอด

เป็นแนวทางการพัฒนาเทคโนโลยีปัญญาประดิษฐ์เพื่อความมั่นคงทางการเงินในอนาคตได้อย่างมีประสิทธิภาพ

ผลการวิจัย

ผู้วิจัยดำเนินการวิเคราะห์และเปรียบเทียบประสิทธิภาพของแบบจำลองตรวจจับการฉ้อโกงทางการเงิน โดยพิจารณาจากค่าความแม่นยำ ความเที่ยง และการเรียกคืน พร้อมทั้งปรับปรุงพารามิเตอร์ด้วยวิธี k-Fold Cross-Validation ที่ค่า k เท่ากับ 5, 10, 15 และ 20 ผลการวิเคราะห์พบว่า เทคนิคต้นไม้ตัดสินใจให้ประสิทธิภาพสูงและมีเสถียรภาพที่ k = 15 และ 20 ขณะที่เทคนิคเพื่อนบ้านที่ใกล้ที่สุดให้ค่าที่เหมาะสมที่สุดที่ k = 15 และลดลงเล็กน้อยที่ k = 20 (Accuracy = 0.996) ส่วนเทคนิคต้นไม้ป่าสุ่มมีค่าความแม่นยำเพิ่มขึ้นตามจำนวนส่วนและสูงสุดที่ k = 20 นอกจากนี้ ได้ทดสอบด้วยการแบ่งข้อมูลแบบ Split Validation ในสัดส่วน 80:20 และ 70:30 เพื่อระบุพารามิเตอร์ที่เหมาะสมที่สุดสำหรับแต่ละเทคนิค ซึ่งผลลัพธ์ของการวิเคราะห์ดังแสดงในตารางที่ 4

ตาราง 4 ประสิทธิภาพการจำแนกประเภทข้อมูล

Classification	Validation	Accuracy (%)	Precision (%)	Recall (%)	F-Measure (%)
Decision Tree	Split Validation (70:30)	99.87	99.89	99.85	99.86
	Split Validation (80:20)	99.80	99.83	99.77	99.80
	Cross-Validation (15 Fold)	99.84	99.82	99.82	99.84
K-Nearest Neighbors	Split Validation (70:30)	99.47	99.46	99.13	99.47
	Split Validation (80:20)	99.40	99.36	99.00	99.42

	Cross-Validation (15 fold)	99.80	99.82	99.75	99.68
Random forest	Split Validation (70:30)	99.60	99.66	99.44	99.60
	Split Validation (80:20)	99.60	99.66	99.53	99.60
	Cross-Validation (20 Fold)	99.52	99.47	99.47	99.37

จากตาราง 4 พบว่า เทคนิคต้นไม้ตัดสินใจ (Decision Tree) ที่ประเมินด้วย Split Validation (70:30) เป็นเทคนิคที่ให้ค่าความแม่นยำสูงสุด เท่ากับ 99.87% และมีค่าความเที่ยงสูงสุด เท่ากับ 99.89% เมื่อเปรียบเทียบกับเทคนิคอื่น ๆ ที่ศึกษา

ตัวเลขที่สูงมากเหล่านี้ไม่เพียงแต่บ่งชี้ถึงความสามารถในการแยกแยะข้อมูลระหว่างคลาสได้อย่างถูกต้องเท่านั้น แต่ยังสะท้อนถึงความสามารถในการลดผลบวกลง (False Positives) ได้อย่างยอดเยี่ยมอีกด้วย ความสำเร็จนี้เน้นย้ำว่า โครงสร้างการตัดสินใจแบบลำดับขั้นของเทคนิคต้นไม้ตัดสินใจ สามารถสร้างขอบเขตการจำแนกที่แม่นยำและเฉพาะเจาะจงสูงสำหรับชุดข้อมูลนี้ได้โดยไม่ต้องใช้ความซับซ้อนของการตรวจสอบความถูกต้องแบบไขว้

ดังนั้นเทคนิคต้นไม้ตัดสินใจ ที่ประเมินด้วยการตรวจสอบถูกต้องแบบแบ่งส่วนข้อมูล (70:30) จึงสรุปได้ว่าเป็นเทคนิคที่เหมาะสมที่สุดและควรได้รับการพิจารณาเป็นอันดับแรกสำหรับการสร้างแบบจำลองจำแนกประเภท เพื่อใช้งานจริงบนชุดข้อมูลที่ทำให้การทดลองนี้เนื่องจาก ให้ผลลัพธ์ที่น่าเชื่อถือที่สุดและสอดคล้องกับวัตถุประสงค์ในการสร้างแบบจำลองที่มีความแม่นยำสูง

สรุปผลและการอภิปราย

การศึกษารุ่นนี้ได้สร้างแบบจำลองการตรวจจับธุรกรรมการฉ้อโกงจากชุดข้อมูล Bank Transaction Dataset for Fraud Detection โดยมี ขั้นตอนที่สำคัญคือการนำเทคนิค K-Means Clustering (K เท่ากับ 5) เพื่อจัดระดับความเสี่ยงธุรกรรมก่อนนำไปเรียนรู้ด้วยโมเดลจำแนกประเภท ผลการทดลองพบว่าเทคนิคต้นไม้ตัดสินใจ มีประสิทธิภาพสูงสุดด้วยค่า

ความแม่นยำเท่ากับ 99.87%, ค่าความเที่ยงเท่ากับ 99.89% และค่าเรียกคืนเท่ากับ 99.85% ซึ่งสูงกว่าการใช้เทคนิคเพื่อนบ้านที่ใกล้ที่สุด และ ต้นไม้ป่าสุ่ม ในชุดข้อมูลนี้ อย่างมีนัยสำคัญ

เมื่อเปรียบเทียบกับงานวิจัยที่เกี่ยวข้อง พบว่าโมเดลที่นำเสนอให้ผลลัพธ์ที่โดดเด่นกว่างานของ Manorom et al. (2024) ซึ่งใช้ตัวแปร ช่องทางธุรกรรม (ChannelCode) และจำนวนครั้งที่ล็อกอิน (LoginAttempts) (ค่าความแม่นยำ 80.00%) [16] และงานของ Khorasani ที่ใช้ Gini Index (ค่าความแม่นยำ 93.50%) [17] ขณะที่ประสิทธิภาพใกล้เคียงกับงานของ Comparative Assessment of Fraudulent Financial Transactions using the Machine Learning Algorithms [18] (ค่าความแม่นยำ 99.86%) แต่มีความสมดุลของค่าความเที่ยงและ ค่าเรียกคืน ที่ดีกว่า

สาเหตุที่เทคนิคต้นไม้ตัดสินใจให้ประสิทธิภาพสูงกว่าต้นไม้ป่าสุ่มในบริบทนี้ เนื่องจากชุดข้อมูลที่มีการจัดกลุ่มข้อมูล (Clustering) มีขอบเขตการจำแนก (Decision Boundary) ที่ชัดเจน ส่งผลให้เทคนิคต้นไม้ตัดสินใจสามารถสร้างกฎที่แม่นยำได้โดยมีค่าความลำเอียง (Bias) ต่ำ ในขณะที่เทคนิคต้นไม้ป่าสุ่มซึ่งใช้การสุ่มเลือกคุณลักษณะ (Feature Subsampling) อาจลดทอนอิทธิพลของตัวแปรหลักและเกิดการเฉลี่ยผลลัพธ์ที่มากเกินไป (Over-smoothing) ผลลัพธ์นี้ยืนยันว่าการปรับจูนความลึกที่เหมาะสมช่วยให้โมเดลที่มีความซับซ้อนต่ำสามารถจำแนกพฤติกรรมฉ้อโกงได้อย่างมีประสิทธิภาพ และพร้อมสำหรับการประยุกต์ใช้ในระบบตรวจจับธุรกรรมดิจิทัลเพื่อสร้างความเชื่อมั่นและความมั่นคงทางการเงินในอนาคต

ข้อเสนอแนะ

สำหรับการวิจัยในอนาคต ควรยกระดับประสิทธิภาพการตรวจจับธุรกรรมขนาดใหญ่โดยการประยุกต์ใช้เทคนิคขั้นสูง อาทิ Deep Learning หรือ Ensemble Learning เช่น XG Boost เพื่อก้าวข้ามขีดจำกัดของแบบจำลองพื้นฐาน ควบคู่กับการทำ Feature Engineering และการวิเคราะห์จัดลำดับความสำคัญของตัวแปร (Feature Importance Ranking) เพื่อระบุปัจจัยหลักที่มีอิทธิพลต่อการทุจริตอย่างมีนัยสำคัญ นอกจากนี้ ควรนำเทคนิคปัญญาประดิษฐ์ที่สามารถอธิบายได้ (Explainable AI: XAI) มาช่วยสร้างความโปร่งใสและตีความเหตุผลเบื้องหลังการตัดสินใจของแบบจำลอง ซึ่งจะช่วยให้องค์กรสามารถนำกฎเกณฑ์ที่ค้นพบไปกำหนดนโยบายบริหารความเสี่ยงได้อย่าง

แม่นยำ ทั้งนี้ ควรมีการทดสอบแบบจำลองกับข้อมูลใหม่อย่างต่อเนื่องผ่านกระบวนการตรวจสอบความถูกต้องแบบไขว้ เพื่อรักษาความเสถียรและความทนทานของระบบภายใต้สภาวะข้อมูลที่เปลี่ยนแปลงตลอดเวลา

ผู้เขียนได้ตรวจสอบเนื้อหาที่สร้างโดย AI อย่างรอบคอบเพื่อให้มั่นใจในความถูกต้อง ความเป็นต้นฉบับ และการปฏิบัติตามหลักจริยธรรมทางวิชาการ”

คำชี้แจงการใช้ AI

ผู้เขียนมีการใช้เครื่องมือปัญญาประดิษฐ์ (ChatGPT และ Gemini) เพื่อสนับสนุนการเรียบเรียงบทความ ได้แก่ การปรับปรุงไวยากรณ์บทความภาษาอังกฤษ การจัดรูปแบบตาราง การสรุปข้อเสนอแนะ และการเกลี้ยกล่อมคำในส่วนสรุปผลวิจัยให้มีความชัดเจนยิ่งขึ้น ทั้งนี้ ผู้เขียนได้ตรวจสอบและกลั่นกรองเนื้อหาทั้งหมดด้วยตนเอง เพื่อยืนยันความถูกต้อง ความเป็นต้นฉบับ และความสอดคล้องกับจริยธรรมทางวิชาการ โดยเนื้อหาเชิงวิเคราะห์และการแปลผลการทดลองทั้งหมดยังคงเป็นความรับผิดชอบของผู้เขียนแต่เพียงผู้เดียว

เอกสารอ้างอิง

- [1] S. V. Khorasani, “Bank Transaction Dataset for Fraud Detection”, Kaggle, 2003. [Online]. Available: <https://www.kaggle.com/datasets/valakhorasani/bank-transaction-dataset-for-fraud-detection>
- [2] FraudGuard Analytics, “Bank Transactions Analysis: The Impact of Data Imbalance on Random Forest Performance,” Unpublished White Paper, Bangkok, Thailand, 2023. [Online]. Available: [https://www.google.com/search?q=https://scholar.google.com/scholar%3Fhl%3Den%26as_q%3DJJournal%2Bof%2BScience%2Band%2BTechnology%2B29\(1\)](https://www.google.com/search?q=https://scholar.google.com/scholar%3Fhl%3Den%26as_q%3DJJournal%2Bof%2BScience%2Band%2BTechnology%2B29(1))
- [3] P. Manorom, N. Sookplang, and C. Khunthong, “Credit/Debit Card Fraud Detection using 5 Machine Learning Algorithms,” *Journal of Science and Technology*, vol. 29, no. 1, pp. 1–15, 2024.

- [4] B. C. da Rocha and R. T. de Sousa Júnior, "Identifying Bank Frauds Using CRISP-DM and Decision Trees," Unpublished Manuscript,[Online].Available: https://www.researchgate.net/publication/47619350_Identifying_Bank_Frauds_Using_CRISP-DM_and_Decision_Trees
- [5] V. Alakhorasani, "Bank Transaction Dataset for Fraud Detection," *Kaggle*, 2023.[Online]. Available:<https://www.kaggle.com/datasets/valakhorasani/bank-transaction-dataset-for-fraud-detection>
- [6] Y. Kou, C. Lu, S. Sirwongwattana, and Y.-P. Huang, "Survey of fraud detection techniques," *IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews)*, vol. 37, no. 6, pp. 103–112, 2021.
- [7] J. West and M. Bhattacharya, "Intelligent financial fraud detection: A comprehensive review," *Computers & Security*, vol. 57, pp. 47–66, 2016.
- [8] M. A. Nielsen and T. V. Nielsen, "Geographical anomaly detection in financial transactions," *IEEE Access*, vol. 9, pp. 110234–110245, 2021.
- [9] Z. Chen, K. Chen, and S. Huang, "Detecting fraudulent online transactions using hybrid machine learning models," *IEEE Access*, vol. 8, pp. 175964–175975, 2020.
- [10] H. Nguyen and B. Le, "Customer behavior analysis indigital banking using demographic segmentation," *Expert Systems with Applications*, vol. 190, 2022.
- [11] A. Dal Pozzolo, G. Boracchi, and G. Bontempi, "Credit card fraud detection using adaptive supervised learning," *IEEE Computational Intelligence Magazine*, vol. 15, no. 1, pp. 45–55, 2020.
- [12] J.-C. Chouinard, "Decision Trees in Machine Learning (with Python Examples)," Sept. 25, 2023. [Online]. Available: <https://www.jcchouinard.com/decision-trees-in-machine-learning/>
- [13] GeeksforGeeks, "KNearest- Neighbor (KNN) Algorithm," Aug. 23, 2025. [Online]. Available: <https://www.geeksforgeeks.org/machine-learning/k-nearest-neighbours/>
- [14] Y. Gujjidi, A. Katti, and R. Agarwal, "Credit Card Fraud Detection Using Hybrid Machine Learning Algorithm," in *Proceedings of World Conference on Artificial Intelligence: Advances and Applications*, A. K. Tripathi, D. Anand, and A. K. Nagar, Eds. Springer, 2023, pp. 303–316.
- [15] อนุพงศ์ สุขประเสริฐ, การทำเหมืองข้อมูลด้วยโปรแกรม Altair AI Studio. คณะการบัญชีและการจัดการ มหาวิทยาลัยมหาสารคาม. 2568.
- [16] Rahman, A., Jannata, R., Rasyid, R., Putra Bintang, P., & Rizqi, H. M. (2024). *Classifying Banking Fraud Determinants with R*. University of Indonesia. ใน โป ร เ จ ก ต์ "Introduction to Data Science".Oct.16,2025.[Online].Available: https://www.researchgate.net/figure/Recall-of-All-Models_fig6_393715947
- [17] S. Rosidin and A. Kurniasari, "Classification Model for Online Payment Transaction Fraud Using a Decision Tree Based on the Gini Index," *Indonesian Journal of Sustainability*, vol. 4, no. 2, 2025.
- [18] P. Manorom, U. Detthamrong, W. Chansanam, "Comparative Assessment of Fraudulent Financial Transactions using the Machine Learning Algorithms Decision Tree, Logistic Regression, Naïve Bayes, K-Nearest Neighbor, and Random Forest," *Engineering, Technology & Applied Science Research*, vol. 14, no. 4, pp. 15676–15680, Aug. 2024.
- [19] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proceedings of the 22nd*

ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16), 2016, pp.785-794-

- [20] Bolton, R. J., & Hand, D. J. (2002). **Statistical Fraud Detection: A Review**. Statistical Science, 17(3), 235–249.
- [21] G. James, D. Witten, T. Hastie, and R. Tibshirani, An Introduction to Statistical Learning: With Applications in R (Chapter 5: Resampling Methods). Springer, 2013. [Online]. Available: <https://www.statlearning.com/>
- [22] S. M. Lundberg and S. I. Lee, “A Unified Approach to Interpreting Model Predictions,” in *Advances in Neural Information Processing Systems (NIPS 2017)*, 2017, vol. 30, pp. 4765-4774.