

การจำแนกประเภทข้อมูลเพื่อการพยากรณ์ความเสี่ยง การฆ่าตัวตายในระยะเริ่มต้น

Classification Approach for Early Prediction of Suicide Risk

พรหล้า ป้องคำ¹, นลธวัช พิมหาญทวีทรัพย์² และ สงกรานต์ หนูน้อย²

¹สาขาธุรกิจดิจิทัลและระบบสารสนเทศ คณะบัญชีและการจัดการ มหาวิทยาลัยมหาสารคาม

Emails: 66010916004@msu.ac.th, 66010916015@msu.ac.th, 66010916021@msu.ac.th

บทคัดย่อ

งานวิจัยฉบับนี้มีวัตถุประสงค์เพื่อสร้างแบบจำลอง และเปรียบเทียบประสิทธิภาพแบบจำลอง โดยใช้เทคนิคการเรียนรู้ของเครื่อง (Machine learning) สำหรับการพยากรณ์ความเสี่ยงการฆ่าตัวตายในระยะเริ่มต้น และนำข้อมูลมาวิเคราะห์ตามกระบวนการมาตรฐานในเทคนิคการเรียนรู้ของเครื่อง (Cross-Industry Standard Process for Data Mining: CRISP-DM) เครื่องมือที่ใช้ในการสร้างแบบจำลอง คือ โปรแกรม Altair AI Studio โดยใช้เทคนิคการจำแนกประเภทข้อมูล (Classification) 4 วิธีได้แก่ ต้นไม้ตัดสินใจ (Decision Tree), ป่าไม้สุ่ม (Random Forest), ซัพพอร์ตเวกเตอร์แมชชีน (Support Vector Machine) และ โครงข่ายประสาทเทียม (Neural Net) พร้อมทั้งประเมินผลลัพธ์ด้วยตัวชี้วัดทางสถิติ ได้แก่ ค่าความแม่นยำ (Accuracy) ค่าความไว (Sensitivity) ค่าความจำเพาะ (Specificity) และ ค่าประสิทธิภาพโดยรวม (F-Measure) อีกทั้งยังทำการเพิ่มประสิทธิภาพของแบบจำลองด้วยวิธีการหาค่าที่เหมาะสมที่สุด (Optimization) ผลการวิจัยพบว่า เทคนิคป่าไม้สุ่มเป็นเทคนิคที่มีความเหมาะสมมากที่สุดในการสร้างแบบจำลองเพื่อการพยากรณ์ความเสี่ยงการฆ่าตัวตายในระยะเริ่มต้น โดยค่าความแม่นยำมากที่สุดถึง 88.70% ค่าความไว เท่ากับ 86.06% ค่าความจำเพาะ เท่ากับ 90.79% และ ประสิทธิภาพโดยรวม เท่ากับ 87.09% แสดงให้เห็นว่าแบบจำลองที่สร้างขึ้นสามารถจำแนกความเสี่ยงการฆ่าตัวตายในระยะเริ่มต้นได้ สามารถนำไปเป็นแนวทางเบื้องต้นในการพัฒนา

ระบบคัดกรองหรือติดตามกลุ่มเสี่ยงในสถาบันการศึกษาและหน่วยงานด้านสาธารณสุขต่อไป

คำสำคัญ – ความเสี่ยงการฆ่าตัวตาย, จำแนกประเภทข้อมูล, ต้นไม้ตัดสินใจ, ป่าไม้สุ่ม, ซัพพอร์ตเวกเตอร์แมชชีน, โครงข่ายประสาทเทียม

ABSTRACT

The objective of this research is to develop a model and compare model performance using machine learning (ML) techniques for predicting early-stage suicide risk. Data analysis was conducted following the Cross-Industry Standard Process for Data Mining (CRISP-DM).

The tool used for model building was the Altair AI Studio program, employing four classification techniques: Decision Tree, Random Forest, Support Vector Machine (SVM), and Neural Net. The results were evaluated using statistical metrics, namely Accuracy, Sensitivity, Specificity, and F-Measure. The models were also optimized to enhance their efficiency.

The research findings revealed that the Random Forest technique was the most suitable for building the early-stage suicide risk prediction model. It achieved the highest Accuracy at 88.70%, a Sensitivity of 86.06%, a Specificity of 90.79% and a F-Measure of 87.09%. This

demonstrates the model's capability to classify early-stage suicide risk effectively. The developed model can serve as a preliminary guideline for the future development of screening or monitoring systems for at-risk groups in educational institutions and public health units.

Keywords – Suicide Risk, Classification, Decision Tree, Random Forest, Support Vector Machine, Neural Net

1. บทนำ

จากรายงานสถิติการฆ่าตัวตายของประเทศไทย ปีงบประมาณ 2566 พบว่า คนไทยเสียชีวิตจากการฆ่าตัวตาย 5,172 คน หรือเท่ากับ 7.94 ต่อแสนประชากร เฉลี่ยวันละ 14 คน หรือเสียชีวิต 1 คน ในทุก 2 ชั่วโมง และคนไทยพยายามฆ่าตัวตาย 31,110 คน หรือเท่ากับ 47.74 ต่อแสนประชากร เฉลี่ยวันละ 85 คน หรือมีผู้พยายามฆ่าตัวตาย 7 คน ในทุก 2 ชั่วโมง [1] โดยพฤติกรรมกรรมการฆ่าตัวตายและการพยายามฆ่าตัวตายที่ไม่ถึงตาย เป็นปัญหาสาธารณสุขที่ทั่วโลกให้ความสำคัญ ข้อมูลทางวิชาการรองรับการอนามัยโลกอธิบายว่า ในผู้ที่มีความคิดอยากตาย จะมีพฤติกรรมพยายามฆ่าตัวตาย (Attempt suicide) กว่า 20 ครั้ง ถึงจะตายสำเร็จ (Completed suicide) นั่นเป็นสาเหตุหนึ่งที่ทำให้ผู้เกี่ยวข้องจึงได้หาวิธีป้องกัน และถือว่าพฤติกรรมกรรมการฆ่าตัวตายนั่น เป็นการตายก่อนวัยอันควรที่สามารถป้องกัน [2]

งานวิจัยฉบับนี้จึงนำเทคนิคการเรียนรู้ของเครื่อง (Machine Learning) มาประยุกต์ใช้ในการวิเคราะห์และจำแนกปัจจัยเสี่ยงที่สัมพันธ์กับการฆ่าตัวตาย เนื่องจากสามารถช่วยในการสร้างแบบจำลองที่ใช้พยากรณ์ความเสี่ยงได้อย่างเป็นระบบ และมีความแม่นยำ โดยมุ่งเน้นการใช้เทคนิค การจำแนกประเภทข้อมูล (Classification) เพื่อวิเคราะห์ปัจจัยที่ส่งผลกระทบต่อความเสี่ยงการฆ่าตัวตายในระยะเริ่มต้น ผลลัพธ์ที่ได้จากการสร้างแบบจำลอง จะช่วยให้สามารถจำแนกกลุ่มเสี่ยงการฆ่าตัวตายในระยะเริ่มต้นได้อย่างมีประสิทธิภาพ ซึ่งเป็นประโยชน์ต่อการนำไปประยุกต์ใช้ในการพัฒนาระบบคัดกรอง การป้องกัน และการติดตามดูแลกลุ่มเสี่ยงในหน่วยงานด้านการศึกษาและสาธารณสุขได้


2. วัตถุประสงค์

2.1 เพื่อสร้างแบบจำลองการจำแนกประเภทข้อมูล (Classification Model) สำหรับการพยากรณ์ความเสี่ยงการฆ่าตัวตายในระยะเริ่มต้น

2.2 เพื่อเปรียบเทียบประสิทธิภาพแบบจำลอง การจำแนกประเภทข้อมูล (Classification Model) สำหรับการพยากรณ์ความเสี่ยงการฆ่าตัวตายในระยะเริ่มต้น

3. วิธีการดำเนินการ

งานวิจัยนี้ดำเนินการวิเคราะห์ข้อมูลตามกระบวนการมาตรฐานของเทคนิคการเรียนรู้ของเครื่อง (Cross-Industry Standard Process for Data Mining: CRISP-DM) ซึ่งกระบวนการนี้เป็นกระบวนการมาตรฐานที่ใช้สำหรับเทคนิคการเรียนรู้ของเครื่อง เพื่อทำการวิเคราะห์และนำไปใช้ประโยชน์ทางธุรกิจ [3] โดยขั้นตอนการประมวลผลข้อมูลตามกระบวนการมาตรฐานในเทคนิคการเรียนรู้ของเครื่อง (CRISP-DM) แบ่งออกเป็น 6 ขั้นตอน ดังนี้



รูปภาพที่ 1 กระบวนการมาตรฐานในเทคนิคการเรียนรู้ของเครื่อง

ที่มา : คัดลอกมาจาก [12].CRISP-DM Process Diagram. สืบค้นเมื่อ 14 ตุลาคม 2568, จาก https://en.wikipedia.org/wiki/Crossindustry_standard_process_for_data_mining

3.1 การทำความเข้าใจเกี่ยวกับปัญหา (Problem Understanding)

การฆ่าตัวตายถือเป็น ปัญหาสาธารณสุขและปัญหาสังคมที่มีความสำคัญและซับซ้อนอย่างยิ่ง ซึ่งก่อให้เกิดความสูญเสียที่มีผลกระทบอย่างรุนแรงต่อระดับครอบครัว ชุมชน และประเทศชาติ การสูญเสียดังกล่าวทวีความรุนแรงขึ้นเมื่อพิจารณาจากความถี่ของปัญหาที่เพิ่มขึ้นอย่างต่อเนื่องในปัจจุบัน ประกอบกับ

การที่ผู้คนในสังคมต้องเผชิญกับ ระดับความเครียดและความกดดันที่สูงขึ้น ในขณะที่ระดับ ความเข้มแข็งของสุขภาพจิตกลับลดลง ประสบการณ์การสูญเสียบุคคลอันเป็นที่รักหรือคนใกล้ชิดจากการฆ่าตัวตายนั้นเป็นสิ่งที่เกิดขึ้นบ่อยครั้งในสังคมยุคปัจจุบัน ซึ่งส่งผลกระทบต่ออารมณ์ สภาพจิตใจ และความผาสุกของครอบครัวที่ประสบเหตุการณ์ดังกล่าว ด้วยเหตุนี้ การทำความเข้าใจอย่างลึกซึ้งซึ่งเกี่ยวกับปัญหาการฆ่าตัวตาย การมีความรู้เพื่อใช้ สังเกตอาการผิดปกติ และการให้ ความช่วยเหลือเบื้องต้นอย่างทันท่วงที จึงเป็นประเด็นที่มีความน่าสนใจและมีความจำเป็นเร่งด่วน หากมีการนำความรู้และแนวทางปฏิบัติดังกล่าวไปประยุกต์ใช้อย่างจริงจัง ย่อมจะนำไปสู่การ ลดความสูญเสียในชีวิตและทรัพย์สินของประชากรในสังคมได้อย่างมีนัยสำคัญ [4]การป้องกันการฆ่าตัวตายอย่างมีประสิทธิภาพจำเป็นต้องอาศัยกลไกการ คัดกรองและพยากรณ์ความเสี่ยงตั้งแต่ระยะเริ่มต้น ก่อนที่สถานการณ์จะถึงขั้นวิกฤต

3.2 การทำความเข้าใจเกี่ยวกับข้อมูล (Data Understanding)

งานวิจัยนี้ได้ศึกษาและนำข้อมูลมาจาก Kaggle โดยใช้ชุดข้อมูล Early Suicide Prediction Dataset [5] เพื่อนำมาใช้ในการพัฒนาแบบจำลองการจำแนกประเภทเพื่อพยากรณ์ความเสี่ยงต่อการพยายามฆ่าตัวตาย (Suicide Attempt) ของนักศึกษาสายวิทยาศาสตร์สุขภาพ ชุดข้อมูลดังกล่าวจัดเก็บในรูปแบบไฟล์ CSV ชุดข้อมูลมีขนาด 1,099 ตัวอย่าง 12 แอตทริบิวต์ ข้อมูลประกอบด้วยทั้งตัวแปรเชิงปริมาณ ได้แก่ อายุ (Age) และตัวแปรเชิงคุณภาพ ได้แก่ ระดับความเครียด (Stress Level) ผลการเรียน (Academic Performance) สถานะความสัมพันธ์ (Relationship Condition) แหล่งที่มาหรือประเภทของการสนับสนุนทางจิตใจ (Mental Support) ระดับความวิตกกังวล (Anxiety Level) ระดับอาการซึมเศร้า (Depression Level) ปัญหาที่เกิดขึ้นภายในครอบครัว (Family Problem) สภาวะทางสุขภาพร่างกาย (Health Condition) ผลการเรียนหรือผลการปฏิบัติงานทางวิชาการ (Academic Performance) เพศ (Gender) และ ประวัติการทำร้ายตัวเอง (Self-Harm Story) ตัวแปรเป้าหมาย คือ ความพยายามฆ่าตัวตาย (Suicide Attempt) โดยจำแนกเป็น 3 กลุ่ม ได้แก่ ไม่เคยคิดฆ่าตัวตาย (Never Thought), คิดแต่ยังไม่เคยพยายามฆ่าตัวตาย (Thought) และ พยายามฆ่าตัวตายแล้ว(Attempted) ชุดข้อมูลนี้เหมาะสำหรับการนำไปวิเคราะห์ด้วยเทคนิคการเรียนรู้ของ

เครื่อง (Machine Learning) เพื่อสร้างแบบจำลองจำแนกประเภท (Classification Model) สำหรับการคาดการณ์ความเสี่ยงการฆ่าตัวตายในกลุ่มนักศึกษา รวมถึงการศึกษาความสัมพันธ์ระหว่างปัจจัยด้านจิตใจและสังคมกับพฤติกรรมความคิดฆ่าตัวตาย

3.3 การเตรียมข้อมูล (Data Preparation)

การเตรียมข้อมูลเป็นขั้นตอนสำคัญเพื่อให้ข้อมูลมีความเหมาะสมและพร้อมสำหรับการฝึกฝนแบบจำลองจำแนกประเภท (Classification) ทั้ง ต้นไม้ตัดสินใจ (Decision Tree), ป่าไม้สุ่ม (Random Forest), ซัพพอร์ตเวกเตอร์แมชชีน (Support Vector Machine) และ โครงข่ายประสาทเทียม (Neural Net) โดยครอบคลุมการจัดการกับค่าที่หายไป ค่าผิดปกติ และการเข้ารหัสตัวแปรจำแนกประเภท ดังนี้

3.3.1 การคัดเลือกข้อมูล (Data Selection)

ผู้วิจัยได้ทำการคัดเลือกตัวแปรด้วยวิธีการคัดเลือกปัจจัยหรือการคัดเลือกคุณสมบัติ (Feature Selection) โดยเลือกใช้แบบคำนวณค่าน้ำหนักของแต่ละแอตทริบิวต์ (Information Theory) ด้วยค่า Information Gain (IG) หลังจากทำการ weight น้ำหนักของค่า Information Gain เพื่อคัดเลือกแอตทริบิวต์เข้าไปใช้สำหรับการสร้างแบบจำลอง พบว่าคุณลักษณะที่มี weight ต่ำกว่าเกณฑ์ที่กำหนด คือแอตทริบิวต์ประวัติการทำร้ายตัวเอง (Self-Harm Story) ดังนั้นจึงตัดสินใจตัดแอตทริบิวต์ ประวัติการทำร้ายตัวเองออกจากการสร้างแบบจำลอง แม้ว่าแอตทริบิวต์ประวัติการทำร้ายตัวเอง จะมีความเกี่ยวข้องกับ ความพยายามฆ่าตัวตาย (Suicide Attempt) อย่างชัดเจน แต่เมื่อคำนวณค่าน้ำหนักด้วย Information Gain พบว่าตัวแปรนี้มี ค่าน้ำหนักต่ำกว่าเกณฑ์ (Threshold) ที่กำหนดไว้ หรือมีค่าน้ำหนักต่ำกว่ากลุ่มตัวแปรหลักอื่น ๆ ซึ่งให้เห็นว่า ตัวแปรนี้ ไม่ได้ช่วยลดความไม่แน่นอน (Entropy) ของตัวแปรเป้าหมาย(label) ได้อย่างมีประสิทธิภาพ ดังนั้นในการศึกษาครั้งนี้จึงพิจารณาตัวแปรต้น ทั้งหมดจำนวน 10 ตัวแปร (รวมตัวแปรตามเป็น 11 แอตทริบิวต์) ได้แก่ อายุ (Age), ระดับความเครียด (Stress Level), ผลการเรียน (Academic Performance), สถานะ ความสัมพันธ์ (Relationship Condition), แหล่งที่มาหรือประเภทของการสนับสนุนทางจิตใจ (Mental Support), ระดับความวิตกกังวล (Anxiety Level), ระดับอาการซึมเศร้า (Depression Level), ปัญหาที่เกิดขึ้นภายในครอบครัว (Family Problem), สภาวะทางสุขภาพ

ร่างกาย (Health Condition), ผลการเรียนหรือผลการปฏิบัติงานทางวิชาการ (Academic Performance) และ เพศ (Gender)

3.3.2 การปรับค่าตัวแปรเป้าหมาย (Label Transformation)

ตัวแปร Suicide Attempt เดิมมีทั้งหมด 3 กลุ่ม ได้แก่ Never Thought (ไม่เคยคิดฆ่าตัวตาย), Thought (เคยคิดฆ่าตัวตายแต่ไม่ได้ลงมือ) และ Attempted (พยายามฆ่าตัวตาย) เพื่อให้การจำแนกประเภทมีความชัดเจนและลดความซับซ้อนของข้อมูล จึงได้ทำการปรับค่าของตัวแปรนี้ให้เหลือเพียง 2 กลุ่ม (Binary Classification) ได้แก่ Never Thought คือ กลุ่มที่ไม่มีแนวโน้มฆ่าตัวตาย (Negative Class) และ Attempted คือ กลุ่มที่มีแนวโน้มพยายามฆ่าตัวตาย (Positive Class) โดยทำการรวมกลุ่ม Thought เข้ากับ Never Thought เนื่องจากเป็นกลุ่มที่ “ยังไม่ได้ลงมือกระทำ” ซึ่งมีลักษณะใกล้เคียงกันในเชิงพฤติกรรม เพื่อให้แบบจำลองสามารถเรียนรู้ความแตกต่างระหว่าง “ผู้ที่ไม่เสี่ยง” และ “ผู้ที่มีเสี่ยงสูง” ได้อย่างมีประสิทธิภาพมากขึ้น

3.3.3 การจัดการค่าผิดปกติ (Outliers)

การตรวจสอบเบื้องต้นจากข้อมูลชุดนี้เผยให้เห็นประเด็นสำคัญที่ต้องแก้ไข

3.3.3.1 ค่าผิดปกติ (Outlier) ในตัวแปร Age พบค่าสูงสุดที่ 221 ในขณะที่ค่าเฉลี่ยอยู่ที่ประมาณ 22.6 ซึ่งบ่งชี้ว่าเป็นค่าที่ผิดพลาดในการบันทึกข้อมูล หรือเป็นค่าที่ไม่ได้เป็นตัวแทนของกลุ่มประชากรที่ศึกษา จึงได้ดำเนินการ ลบ (Removal) แถวข้อมูลที่มีค่าผิดปกตินี้ออก เพื่อรักษาความถูกต้องของแบบจำลองและเน้นกลุ่มประชากรที่สนใจเกี่ยวข้องกับ "นักเรียน/นักศึกษา", "วัยรุ่น" และตั้งขีดจำกัดที่ 30 ปี คือการกำหนดขอบเขตการศึกษาให้ตรงกับกลุ่มเป้าหมายอย่างชัดเจน

3.3.3.2 ค่าที่หายไป/ค่าผิดปกติในตัวแปร Nominal ในตัวแปร Depression Level และ Anxiety Level พบข้อมูลที่มีการบันทึกค่าที่ผิดปกติหรือหายไปจำนวนน้อยมาก (เพียง 1 ค่า) จึงดำเนินการ ลบค่า 'pf' ใน Depression Level และ แก้ไข 'sometimes' ที่คาดว่าเกิดจากการสะกดผิด ใน Anxiety Level เป็น 'Sometimes'

3.3.4 การแปลงตัวแปรจำแนกประเภท (Categorical Feature Encoding)

ตัวแปรจำแนกประเภท (Nominal/Ordinal) จำเป็นต้องแปลงให้อยู่ในรูปแบบตัวเลขเพื่อให้แบบจำลองเรียนรู้ได้อย่างถูกต้อง โดยใช้แนวทางดังนี้

3.3.4.1 Ordinal Data (มีลำดับ)

ตัวแปรแบบลำดับ (Ordinal) คือ ตัวแปรที่มีการเรียงลำดับความมากน้อยหรือความเข้มข้นที่ชัดเจน การแปลงจึงต้องสะท้อนลำดับนั้นเพื่อรักษาความสัมพันธ์เชิงปริมาณ (Magnitude) ของข้อมูลไว้ งานวิจัยฉบับนี้จึงดำเนินการแปลงแอตทริบิวต์ที่เป็นข้อมูลแบบลำดับ ให้เป็นข้อมูลตัวเลข (Numeric) โดยมีลำดับจากน้อยไปมาก เพื่อให้แบบจำลองสามารถประมวลผลข้อมูลได้ และเพื่อให้ตัวแปรเหล่านี้มีลำดับหรือระดับความเข้มข้นที่ชัดเจน การแปลงจึงต้องสะท้อนลำดับนั้นด้วยค่าตัวเลขที่เรียงกัน ดังนี้ ระดับความเครียด (Stress Level) จำแนกเป็น 3 ระดับ ได้แก่ 1 (Low), 2 (Moderate) และ 3 (High) ผลการเรียนหรือผลการปฏิบัติงานทางวิชาการ (Academic Performance) จำแนกเป็น 4 ระดับ ได้แก่ 1 (Good), 2 (Poor), 3 (Excellent) และ 4 (Average) สภาวะทางสุขภาพร่างกาย Health Condition จำแนกเป็น 3 ระดับ ได้แก่ 1 (Normal), 2 (Fair) และ 3 (Abnormal) ระดับอาการซึมเศร้า (Depression Level) จำแนกเป็น 3 ระดับ ได้แก่ 1 (Sometime), 2 (Often) และ 3 (Always) ระดับความวิตกกังวล (Anxiety Level) จำแนกเป็น 3 ระดับ ได้แก่ 1 (sometimes), 2 (Often) และ 3 (Always)

3.3.4.2 Nominal Data (ไม่มีลำดับ)

แปลง Attribute ที่เป็นข้อมูลจำแนกประเภทที่ไม่มีลำดับ (Nominal) จำเป็นต้องแปลงให้อยู่ในรูปแบบตัวเลขเช่นเดียวกัน เพื่อให้แบบจำลองสามารถประมวลผลได้ โดยการเข้ารหัส (Encoding) จะไม่เรียงลำดับค่า แต่เพียงแทนค่าด้วยตัวเลขที่แตกต่างกันเท่านั้น ดังนี้ ปัญหาที่เกิดขึ้นภายในครอบครัว (Family Problem) จำแนกเป็น 3 กลุ่ม ได้แก่ 0 (None), 1 (Parental conflict), 2 (Financial), เพศ (Gender) จำแนกเป็น 2 กลุ่ม ได้แก่ 0 (Female), 1 (Male) แหล่งที่มาหรือประเภทของการสนับสนุนทางจิตใจ (Mental Support) จำแนก

เป็น 3 กลุ่ม ได้แก่ 0 (Family), 1 (loneliness), 2 (Friends)
สถานะความสัมพันธ์ Relationship Condition

Label	Suicide Attempt	Normal	0	Least Attempted (151)	Most Never Thought (610)	Average Never Thought (610), Thought (338), ...[1 more]
Age	Integer	0	19	221	22,859	
Gender	Binomial	0	Female	Male	Male (448), Female (451)	
Stress Level	Normal	0	Least High (174)	Most Low (468)	Low (468), Moderate (457), ...[1 more]	
Academic Performance	Normal	0	Least Average (216)	Most Good (366)	Good (366), Poor (283), ...[2 more]	
Health Condition	Normal	0	Least Abnormal (188)	Most Normal (543)	Normal (543), Fair (368), ...[1 more]	
Relationship Condition	Normal	0	Least Broken (275)	Most In a relationship (413)	In a relationship (413), Single (111), ...[1 more]	
Family Problem	Normal	0	Least Parental conflict (282)	Most Financial (411)	Financial (411), None (406), ...[1 more]	
Depression Level	Normal	0	Least pf (1)	Most Sometimes (334)	Sometimes (334), Often (170), ...[2 more]	
Anxiety Level	Normal	0	Least sometimes (1)	Most Sometimes (468)	Sometimes (468), Often (465), ...[2 more]	
Mental Support	Normal	0	Least loneliness (261)	Most Friends (552)	Friends (552), Family (286), ...[1 more]	
Self Harm Story	Binomial	0	No	Yes	No (891), Yes (208)	

รูปภาพที่ 2 ก่อนแปลงข้อมูล

Label	Suicide Attempt	Binomial	0	Never Thought	Attempted	Average Never Thought (609), Attempted (468)
Gender	Numeric	0	0	1	1	0.599
Relationship Condition	Numeric	0	0	2	2	0.874
Family Problem	Numeric	0	0	2	2	1.906
Mental Support	Numeric	0	0	2	2	1.243
Self Harm Story	Numeric	0	0	1	1	0.189
Academic Performance	Numeric	0	1	4	4	2.500
Health Condition	Numeric	0	1	3	3	1.675
Anxiety Level	Numeric	0	1	3	3	1.723
Depression Level	Numeric	0	1	3	3	1.691
Stress Level	Numeric	0	1	3	3	1.733

รูปภาพที่ 3 หลังการเตรียมข้อมูล

จากนั้นทำการกำหนดหน้าที่ให้กับแอตทริบิวต์ Suicide Attempt ให้มีหน้าที่เป็น Label เพื่อเป็นการระบุว่าตัวแปรนี้คือ “ตัวแปรเป้าหมาย” (Target Variable) ที่เราต้องการให้แบบจำลองเรียนรู้และพยากรณ์ผล ซึ่งจะได้ชุดข้อมูลที่พร้อมสำหรับนำมาใช้ในการพยากรณ์ครั้งนี้ ดังแสดงในตารางที่ 1

ตาราง 1 แสดงรายละเอียดแอตทริบิวต์ทั้งหมดของข้อมูล

ลำดับที่	แอตทริบิวต์	ประเภท	คำอธิบาย
1	Suicide Attempt	Binomial (Label)	ตัวแปรเป้าหมาย (Target Variable)
2	Age	Integer	อายุ
3	Gender	Binomial	เพศ
4	Stress Level	Numeric	ระดับความเครียด
5	Academic Performance	Numeric	ผลการเรียนหรือผลการปฏิบัติงานทางวิชาการ


6	Health Condition	Numeric	สภาวะทางสุขภาพร่างกาย
7	Relationship Condition	Numeric	สถานะความสัมพันธ์
8	Family Problem	Numeric	ปัญหาที่เกิดขึ้นภายในครอบครัว
9	Depression Level	Numeric	ระดับอาการซึมเศร้า
10	Anxiety Level	Numeric	ระดับความวิตกกังวล
11	Mental Support	Numeric	แหล่งที่มาหรือประเภทของการสนับสนุนทางจิตใจ

3.4 การสร้างแบบจำลอง (Modeling)

ผู้วิจัยได้ใช้เทคนิคการจำแนกประเภทข้อมูล (Classification) ด้วยวิธี Decision Tree, Random Forest, Support Vector Machine และ Neural Net การเลือกใช้สามเทคนิคร่วมกันช่วยให้งานวิจัยสามารถประเมินผลได้อย่างรอบด้านโดยรายละเอียดของแต่ละแบบจำลองแสดงดังต่อไปนี้

3.4.1 เทคนิคต้นไม้ตัดสินใจ (Decision Tree)

ต้นไม้ตัดสินใจ เป็นกระบวนการเรียนรู้จำแนกโดยการแบ่งแยกข้อมูลออกเป็นแขนงสาขา ซึ่งค่อนข้างสอดคล้องกับการตัดสินใจจริงของมนุษย์และถูกแสดงเป็นภาพที่เข้าใจง่ายและสามารถทำงานได้กับข้อมูลที่มีความเกี่ยวข้องกับข้อมูลสูง และอาจมีหลายลำดับชั้น โดยมีอัลกอริทึมที่นิยมนำมาใช้ในการสร้างแผนการตัดสินใจ อยู่หลายกระบวนการ เช่น Hunt's Algorithm, CAR, ID3, C4.5 และ SLIQ ซึ่งการสร้างแผนการตัดสินใจ จากข้อมูลที่ต้องทำการเรียนรู้ จะต้องมีการกำหนดคุณลักษณะ (Attribute) และการแบ่งโหนด (Node or split) ของแบบจำลองแผน (Tree) นั้น ซึ่งอาจเป็นไปตามข้อมูลที่ได้นำมา [6]



รูปภาพที่ 4 การแทนต้นไม้ตัดสินใจ

ที่มา: ดัดแปลงจาก [6], เทคนิคการเรียนรู้ของเครื่องด้วยโปรแกรม Altair AI Studio (น.186).

3.4.2 เทคนิคป่าไม้สุ่ม (Random Forest)


ป่าไม้สุ่ม เป็นหนึ่งในกลุ่มของแบบจำลองที่เรียกว่า Ensemble Learning ที่มีหลักการคือการเทรนแบบจำลองที่เหมือนกันหลายๆ ครั้ง (หลาย Instance) บนข้อมูลชุดเดียวกัน โดยแต่ละครั้งของการเทรนจะเลือกส่วนของข้อมูลที่เทรนไม่เหมือนกัน แล้วเอาการตัดสินใจของแบบจำลองเหล่านั้นมาโหวตกันว่า Class ไหนถูกเลือกมากที่สุด [7]

3.4.3 เทคนิคการซัพพอร์ตเวกเตอร์แมชชีน (Support Vector Machine)

เทคนิคการซัพพอร์ตเวกเตอร์แมชชีน (SVM) ใช้ในการวิเคราะห์ข้อมูลและเป็นแนวคิดในการจำแนกประเภทข้อมูลโดยอาศัยหลักการของการหาสมประสิทธิ์ของสมการเพื่อสร้างเส้นแบ่งแยกกลุ่มข้อมูลที่ถูกต้องเข้าสู่กระบวนการเพื่อสอนให้ระบบเรียนรู้ โดยเน้นไปยังเส้นแบ่งข้อมูลซึ่งสามารถใช้เป็นมาตรฐานในการแยกแยะกลุ่มข้อมูลได้ดีที่สุด แนวคิดในการแบ่งกลุ่มข้อมูลด้วยเทคนิคดังกล่าว เกิดจากการที่นำค่าของกลุ่มข้อมูลมาวางลงในฟีเจอร์สเปซ (Feature Space) จากนั้นจึงหาเส้นที่ใช้แบ่งข้อมูลทั้งสองออกจากกัน โดยจะสร้างเส้นแบ่ง (Hyper Plane) ที่เป็นเส้นตรงขึ้นมา และหาว่าเส้นตรงใดเป็นเส้นตรงที่ดีที่สุดเพื่อนำมาช่วยแก้ปัญหาการจำแนกประเภทข้อมูล จำแนกข้อมูลสองกลุ่มออกจากกัน โดยแนวคิดในการแบ่งกลุ่มข้อมูลด้วยเทคนิค Support Vector Machine มักใช้ในการแบ่งกลุ่มออกเป็นสองกลุ่มโดยจะใช้กับชุดข้อมูลที่มีมิติของข้อมูลที่สูง [6]

3.4.4 เทคนิคโครงข่ายประสาทเทียม (Neural Net)

หรือที่มักจะเรียกสั้น ๆ ว่าโครงข่ายประสาท (Neural Net) คือ แบบจำลองทางคณิตศาสตร์ สำหรับประมวลผลสารสนเทศด้วยการคำนวณในลักษณะความสัมพันธ์เชิงเชื่อมโยงระหว่างส่วนหรือแบบคอนเนคชันนิสต์ (Connectionist) เพื่อจำลองการทำงานของเครือข่ายประสาทในสมองมนุษย์ ด้วยวัตถุประสงค์ที่จะสร้างเครื่องมือซึ่งมีความสามารถในการจดจำแบบรูป และการทำนายอนาคต เช่นเดียวกับความสามารถที่มีในสมองมนุษย์ [6]



รูปภาพที่ 5 ข่ายงานประสาทเทียม

ที่มา: ดัดแปลงจาก [6], เทคนิคการเรียนรู้ของเครื่องด้วยโปรแกรม Altair AI Studio (น.225).

3.5 การประเมินผล (Evaluation)

งานวิจัยนี้ได้ดำเนินการแบ่งชุดข้อมูลจำนวน 2 กลุ่ม ด้วยวิธีการ 10-fold cross-validation โดยแบ่งข้อมูลออกเป็น 10 กลุ่ม เท่า ๆ กัน เพื่อใช้สำหรับเป็นข้อมูลในการสอน (Training) และข้อมูลที่ใช้สำหรับการทดสอบแบบจำลอง (Testing) และทำการทดสอบประสิทธิภาพของแบบจำลองด้วย ค่าความแม่นยำ (Accuracy) ค่าความเที่ยง (Precision) ค่าเรียกคืน (Recall) ค่าประสิทธิภาพโดยรวม (F-Measure) และตัวชี้วัดสำคัญสำหรับวิทยาศาสตร์สุขภาพ คือ Sensitivity และ Specificity ในสายวิทยาศาสตร์สุขภาพ การตีความผลลัพธ์ว่า "ใครเป็นผู้ป่วย/เสี่ยง" (Positive) และ "ใครเป็นผู้ที่ไม่ป่วย/ไม่เสี่ยง" (Negative) มีความสำคัญเชิงจริยธรรมและการปฏิบัติ Sensitivity สำคัญที่สุดในการทำนายความเสี่ยง เนื่องจากวัดความสามารถของแบบจำลองในการระบุผู้ที่มีความเสี่ยงจริง (Attempted/Thought) ได้ถูกต้อง การมี Sensitivity สูง หมายถึงการลด False Negative (การวินิจฉัยผิดพลาดว่าไม่เสี่ยง ทั้งที่เสี่ยงจริง) ซึ่งเป็นความผิดพลาดที่มีค่าใช้จ่ายสูงและเสี่ยงอันตรายถึงชีวิตในกรณี Specificity วัดความสามารถของแบบจำลองในการ ระบุผู้ที่ไม่เสี่ยงจริง (Never Thought) ได้ถูกต้อง การมี Specificity สูง หมายถึงการลด False Positive (การวินิจฉัยผิดพลาดว่าเสี่ยง ทั้งที่ไม่เสี่ยงจริง) ซึ่งช่วยลดการใช้ทรัพยากรทางการแพทย์ที่ไม่จำเป็นในการดูแลผู้ที่ไม่ได้มีความเสี่ยงสูงจริง โดยกระบวนการประเมินผลทั้งหมดดำเนินการผ่านโปรแกรม Altair AI Studio

3.5.1 ค่าความแม่นยำ (Accuracy)

ค่าความแม่นยำคือ จำนวนข้อมูลที่ทำนายถูกของทุกคลาส [6] สามารถเขียนอธิบายเป็นสมการในรูปสมการทางคณิตศาสตร์ได้ ดังสมการที่ 1

$$\frac{TP+TN}{TP+TN+FP+FN} \quad (1)$$

3.5.2 ค่าประสิทธิภาพโดยรวม (F-Measure)

$$F - Measure(YES) = \frac{(2*Precision(YES)*Recall(YES))}{(Precision(YES)+Recall(YES))} \quad (2)$$

$$F - Measure(NO) = \frac{(2*Precision(NO)*Recall(NO))}{(Precision(NO)+Recall(NO))} \quad (3)$$

3.5.3 ค่าความไว (Sensitivity)

คือสัดส่วนของผลบวกที่เป็นจริงสำหรับภาวะนั้น ๆ (เช่น สัดส่วนของการตรวจพบโรคในผู้ที่ป่วยจริง) มีไวพจน์เป็นคำอื่น ๆ รวมทั้ง อัตราผลบวกจริง (true positive rate), recall, probability of detection ซึ่งใช้ในสาขาต่าง ๆ [8]

$$sensitivity = \frac{TP}{TP+FN} \quad (4)$$

3.5.4 ค่าความจำเพาะ (Specificity)

คือสัดส่วนของผลลบที่เป็นจริงสำหรับภาวะนั้น ๆ (เช่น สัดส่วนของการตรวจไม่พบโรคในผู้ที่ไม่ป่วย) มีไวพจน์เป็นคำอื่น ๆ รวมทั้ง อัตราผลลบจริง (true negative rate) [8]

$$specificity = \frac{TN}{TN+FP} \quad (5)$$

3.6 การนำแบบจำลองไปใช้งาน (Deployment)

ผลลัพธ์ที่ได้จากการวิเคราะห์ข้อมูลในครั้งนี้จะได้แบบจำลองที่มีความเหมาะสมสำหรับการพยากรณ์ความเสี่ยงการฆ่าตัวตายในระยะเริ่มต้น โดยใช้เทคนิคการเรียนรู้ของเครื่อง ได้แก่ ต้นไม้ตัดสินใจ, ป่าไม้สุ่ม, ซัพพอร์ตเวกเตอร์แมชชีน และโครงข่ายประสาท ซึ่งผ่านกระบวนการเพิ่มประสิทธิภาพของแบบจำลองด้วยวิธีการหาค่าที่เหมาะสมที่สุด เพื่อให้ได้แบบจำลองที่ให้ผลการพยากรณ์ที่มีความถูกต้องสูงสุด โดยแบบจำลองที่ได้สามารถนำไปประยุกต์ใช้ในระบบคัดกรองเบื้องต้น เพื่อช่วยระบุหรือจำแนกกลุ่มบุคคลที่มีความเสี่ยงต่อการฆ่าตัวตายในระยะเริ่มต้น โดยสามารถใช้งานร่วมกับฐานข้อมูลนักศึกษา หรือข้อมูลจากแบบประเมินด้านจิตใจและสังคม เพื่อให้หน่วยงานที่เกี่ยวข้อง เช่น ครูที่ปรึกษา นักจิตวิทยา หรือนักแนะแนว ใช้เป็นข้อมูลประกอบการวางแผนให้ความช่วยเหลือเชิงป้องกันได้อย่างทันทั่วทั้ง

นอกจากนี้ ผลการวิจัยในครั้งนี้สามารถนำไปต่อยอดในการพัฒนาระบบพยากรณ์ความเสี่ยงแบบอัตโนมัติ หรือระบบสนับสนุนการตัดสินใจ (Decision Support System) เพื่อใช้ในการติดตามภาวะสุขภาพจิตของกลุ่มตัวอย่างในระยะยาวได้อย่างมีประสิทธิภาพมากยิ่งขึ้น

4.ผลการวิจัย

ตาราง 2 ผลการเปรียบเทียบประสิทธิภาพของแบบจำลองการจำแนกประเภทเพื่อพยากรณ์ความเสี่ยงต่อการพยายามฆ่าตัวตาย

Classification Technique	Classification Performance		ใช้กรณีที่เป็นการศึกษาเกี่ยวกับสายวิทยาศาสตร์สุขภาพ	
	Accuracy	F-measure	Sensitivity	Specificity
Decision Tree	86.14	84.25	83.18	88.49
Random Forest*	88.70	87.09	86.06	90.79
Support Vector Machine	85.23	82.48	78.28	90.78
Neural Net	86.88	84.94	84.01	89.15

* เป็นเทคนิคที่มีความเหมาะสมที่สุดสำหรับการนำไปสร้างเป็นแบบจำลองการพยากรณ์

จากตารางที่ 2 พบว่าแบบจำลองป่าไม้สุ่ม (Random Forest) ให้ค่าประสิทธิภาพโดยรวมสูงที่สุด โดยมี ค่าความเชื่อมั่น เท่ากับ 88.70% ประสิทธิภาพโดยรวม เท่ากับ 87.09%, ค่าความไว เท่ากับ 83.18% และ ค่าความจำเพาะ เท่ากับ 90.79% แสดงให้เห็นถึงความสามารถของแบบจำลองในการจำแนกกลุ่มผู้ที่มีแนวโน้มพยายามฆ่าตัวตายได้อย่างมีประสิทธิภาพทั้งในด้านการตรวจจับผู้ที่มีความเสี่ยง

(Sensitivity) และการระบุผู้ที่ไม่เสี่ยงได้ถูกต้อง (Specificity) ลำดับถัดมาคือแบบจำลองโครงข่ายประสาทเทียม (Neural Net) โดยมีค่าความเชื่อมั่น เท่ากับ 86.88% ประสิทธิภาพโดยรวม เท่ากับ 84.94% ค่าความไว เท่ากับ 84.01% และ ค่าความจำเพาะ เท่ากับ 89.15% แบบจำลองต้นไม้ตัดสินใจ โดยมีค่าความเชื่อมั่น เท่ากับ 86.14% ประสิทธิภาพโดยรวม เท่ากับ 84.25% ค่าความไว เท่ากับ 83.18% และ ค่าความจำเพาะ เท่ากับ 88.49% และลำดับสุดท้าย แบบจำลอง ซัพพอร์ตเวกเตอร์แมชชีน มีประสิทธิภาพต่ำที่สุดเมื่อเทียบกับแบบจำลองอื่น โดยมีค่าความเชื่อมั่น เท่ากับ 85.23% ประสิทธิภาพโดยรวม เท่ากับ 82.48% ค่าความไว เท่ากับ 78.28% และ ค่าความจำเพาะ เท่ากับ 90.78%

จากผลการเปรียบเทียบพบว่า เทคนิคป่าไม้สุ่ม เป็นเทคนิคที่มีความเหมาะสมที่สุดสำหรับการสร้างแบบจำลองพยากรณ์ความเสี่ยงการพยายามฆ่าตัวตายในระยะเริ่มต้น เนื่องจากให้ค่าประสิทธิภาพสูงสุดในทุกตัวชี้วัดหลัก และมีความสมดุลระหว่างการตรวจจับผู้ที่มีความเสี่ยงและการลดการทำนายผิดพลาดในกลุ่มที่ไม่เสี่ยง ซึ่งมีความสำคัญอย่างยิ่งต่อการนำไปประยุกต์ใช้ในงานด้าน วิทยาศาสตร์สุขภาพ และการประเมินภาวะสุขภาพจิต

สำหรับการวิเคราะห์ข้อมูลครั้งนี้ ผู้วิจัยได้ทำการเพิ่มประสิทธิภาพของแบบจำลองการพยากรณ์ความเสี่ยงการฆ่าตัวตายในระยะเริ่มต้น ด้วยวิธีการหาค่าที่เหมาะสมที่สุด (Optimization) ด้วยวิธีวิวัฒนาการ (Evolutionary Algorithms) เพื่อค้นหาค่าที่เหมาะสมที่สุดสำหรับชุดของพารามิเตอร์ในแบบจำลอง โดยเทคนิคต้นไม้ตัดสินใจ ปรับค่าพารามิเตอร์ criterion ได้แก่ gain ratio, gini index ปรับค่า maximal depth เพื่อควบคุมระดับความลึกของต้นไม้ ปรับค่า minimal gain และ minimal leaf size เพื่อป้องกัน overfitting เทคนิคป่าไม้สุ่ม ได้ทำการหาค่าที่เหมาะสมสำหรับพารามิเตอร์ Number of trees ปรับจำนวนแอตทริบิวต์ที่ใช้ในแต่ละ split (number of attributes) ปรับ maximal depth ของแต่ละต้นไม้ เทคนิคซัพพอร์ตเวกเตอร์แมชชีน ปรับ kernel type ได้แก่ linear, radial, polynomial ปรับค่าพารามิเตอร์ C (ค่า penalty) ปรับค่า gamma ของ kernel เทคนิคโครงข่ายประสาทเทียม ปรับค่า training cycles, learning rate และ ปรับค่า momentum

5. อภิปรายผลการวิจัย

งานวิจัยฉบับนี้มีวัตถุประสงค์เพื่อเปรียบเทียบประสิทธิภาพของแบบจำลองการพยากรณ์ความเสี่ยงการฆ่าตัวตายในระยะเริ่มต้น โดยประยุกต์ใช้เทคนิคเทคนิคการเรียนรู้ของเครื่อง (Machine learning) ผ่านกระบวนการจำแนกประเภทข้อมูล (Classification) จำนวน 4 เทคนิค ได้แก่ เทคนิคต้นไม้ตัดสินใจ (Decision Tree) เทคนิคป่าไม้สุ่ม (Random Forest), เทคนิคซัพพอร์ตเวกเตอร์แมชชีน (Support Vector Machine) และ เทคนิคโครงข่ายประสาทเทียม (Neural Net) การประเมินประสิทธิภาพของแบบจำลอง ซึ่งตัววัดประสิทธิภาพของแบบจำลองประกอบด้วย 4 ตัวชี้วัด ได้แก่ ค่าความแม่นยำ (Accuracy) ค่าประสิทธิภาพโดยรวม (F-Measure) และ ตัวชี้วัดสำคัญสำหรับวิทยาศาสตร์สุขภาพ คือ ค่าความไว (Sensitivity) และ ค่าความจำเพาะ (Specificity) จากผลการวิเคราะห์ข้อมูลด้วยเทคนิคการจำแนกประเภทข้อมูล (Classification) พบว่า แบบจำลอง ป่าไม้สุ่ม ให้ค่าความแม่นยำสูงที่สุด เท่ากับ 88.70% มีค่า ประสิทธิภาพโดยรวม เท่ากับ 87.09%, Sensitivity เท่ากับ 86.06% และ Specificity เท่ากับ 90.79% แสดงให้เห็นว่าแบบจำลองสามารถจำแนกกลุ่มผู้ที่มีแนวโน้มพยายามฆ่าตัวตายได้อย่างมีประสิทธิภาพมากที่สุดเมื่อเทียบกับเทคนิคอื่น ผลลัพธ์ดังกล่าวสอดคล้องกับแนวคิดทางทฤษฎีของป่าไม้สุ่ม ซึ่งเป็นเทคนิคแบบ Ensemble Learning ที่รวมผลจากหลาย ต้นไม้ตัดสินใจ เพื่อเพิ่มความแม่นยำและลดความเอนเอียง (bias) ของแบบจำลอง ทำให้สามารถจัดการกับข้อมูลที่มีความซับซ้อนและไม่เป็นเชิงเส้นได้ดีกว่าแบบจำลองเดี่ยวอื่น ๆ นอกจากนี้ การใช้วิธี ปรับค่าพารามิเตอร์ด้วย Evolutionary Algorithm ช่วยให้ได้ค่าที่เหมาะสมที่สุด (Optimal Parameters) ของแต่ละแบบจำลองทำให้ผลการพยากรณ์มีประสิทธิภาพสูงขึ้น ซึ่งสอดคล้องกับงานวิจัยก่อนหน้านี้ที่พบว่า การปรับแต่งพารามิเตอร์สามารถเพิ่มประสิทธิภาพของแบบจำลองทางสถิติ และการเรียนรู้ของเครื่องได้อย่างมีนัยสำคัญ ซึ่งเทคนิคและตัวแปรปัจจัยที่ใช้ในการสร้างแบบจำลองพยากรณ์ความเสี่ยงการฆ่าตัวตายในระยะเริ่มต้นมีความสอดคล้องกับ [9] ที่ได้พยากรณ์การพยายามฆ่าตัวตายในกลุ่มวัยรุ่นชายเกาหลีใต้ งานวิจัยนี้ใช้ข้อมูลจากการสำรวจพฤติกรรมเสี่ยงของเยาวชน (KYRBS) เพื่อพัฒนาและประเมินประสิทธิภาพของแบบจำลอง Machine Learning ในการจำแนกและค้นหาตัวทำนายสำคัญ (Key Predictors) ของการพยายามฆ่าตัวตาย ในกลุ่มวัยรุ่น ด้วยเทคนิคต้นไม้ตัดสินใจ

(Accuracy เท่ากับ 84.8%) เทคนิคป่าไม้สุ่ม (Accuracy เท่ากับ 84.7%) ซัพพอร์ตเวกเตอร์แมชชีน (Accuracy เท่ากับ 84.1%) โดยได้ใช้ตัวแปรที่สอดคล้องกัน มีดังนี้ เพศ (Sex), อายุ (Age), เกรดการศึกษาและภาวะซึมเศร้า/สิ้นหวัง (Sadness/ Hopelessness) [10] ที่ได้พยากรณ์ความเสี่ยงฆ่าตัวตายทุกระดับ (ความคิด การวางแผน และการพยายาม) ในประชากรผู้ใหญ่ชาวเกาหลี งานวิจัยนี้ใช้ข้อมูลจากการสำรวจสุขภาพและโภชนาการแห่งชาติ (KNHANES) เพื่อเปรียบเทียบอัลกอริทึม ML หลายตัวในการจำแนกกลุ่มผู้มีความเสี่ยงฆ่าตัวตายออกจากกลุ่มประชากรทั่วไป โดยเน้นการหาปัจจัยทางประชากรศาสตร์และจิตสังคมที่สำคัญ โดยได้ใช้ตัวแปรที่สอดคล้องกัน มีดังนี้ ภาวะซึมเศร้า (Depressive symptoms), ความพึงพอใจในชีวิต, รายได้ (Income), เพศ (Sex), อายุ (Age) [11] ที่ได้พยากรณ์ความคิด การวางแผน และการพยายามฆ่าตัวตายในกลุ่มวัยรุ่นที่ยังเรียนอยู่ (School-going adolescents) งานวิจัยนี้ใช้ชุดข้อมูลขนาดใหญ่เพื่อพัฒนาแบบจำลอง ML (โดยเฉพาะ Ensemble methods) ในการพยากรณ์พฤติกรรมที่เกี่ยวข้องกับการฆ่าตัวตาย โดยเน้นการปรับปรุงแบบจำลองให้มีประสิทธิภาพสูงขึ้นบนชุดข้อมูลที่มีความไม่สมดุล (Imbalanced Dataset) โดยได้ใช้ตัวแปรที่สอดคล้องกัน มีดังนี้ เพศ (Gender), ความเหงา (Loneliness), การผูกพันกับผู้ปกครอง (Parental Attachment), สถานะทางเศรษฐกิจ, ประวัติการพยายามฆ่าตัวตาย

ผลการวิเคราะห์ยังสะท้อนให้เห็นว่าปัจจัยด้าน จิตใจและสังคม เช่น ระดับความเครียด ภาวะซึมเศร้า ความวิตกกังวล และปัญหาครอบครัวเป็นตัวแปรสำคัญที่ส่งผลต่อความเสี่ยงต่อการฆ่าตัวตายซึ่งสอดคล้องกับแนวคิดขององค์การอนามัยโลก (WHO) ที่ระบุว่าการประเมินภาวะสุขภาพจิตอย่างรอบด้านตั้งแต่ระยะเริ่มต้นเป็นกุญแจสำคัญในการป้องกันพฤติกรรมฆ่าตัวตาย

6. สรุปผลการวิจัย

งานวิจัยนี้มีวัตถุประสงค์เพื่อพัฒนาแบบจำลองการจำแนกข้อมูล สำหรับการพยากรณ์ความเสี่ยงการฆ่าตัวตายในระยะเริ่มต้น โดยใช้เทคนิคต้นไม้ตัดสินใจ, เทคนิคป่าไม้สุ่ม, เทคนิคซัพพอร์ตเวกเตอร์แมชชีน และ เทคนิคโครงข่ายประสาทเทียม ผ่านกระบวนการมาตรฐานในเทคนิคการเรียนรู้ของเครื่องบนโปรแกรม Altair AI Studio ชุดข้อมูลที่ใช้ประกอบด้วย 1,097 ตัวอย่าง ครอบคลุมปัจจัยด้านประชากรศาสตร์ จิตใจ

และสังคม รวมทั้งหมด 11 แอตทริบิวต์ โดยมี ความพยายามฆ่าตัวตายเป็นตัวแปรเป้าหมายแบบสองคลาส คือ “ไม่มีความเสี่ยง” และ “มีความเสี่ยง” ผลการทดลองพบว่า เทคนิคป่าไม้สุ่มเป็นแบบจำลองที่ให้ประสิทธิภาพสูงที่สุด โดยค่าความเชื่อมั่น เท่ากับ 88.70% รองลงมาคือ เทคนิคโครงข่ายประสาทเทียม เทคนิคต้นไม้ตัดสินใจ และ เทคนิคซัพพอร์ตเวกเตอร์แมชชีน ตามลำดับ แสดงให้เห็นถึงความสามารถของเทคนิคแบบรวบรวมผลลัพธ์ ในการพยากรณ์กลุ่มเสี่ยงได้อย่างแม่นยำและสมดุล แบบจำลองที่พัฒนาได้สามารถนำไปประยุกต์ใช้เป็น ระบบคัดกรองเชิงป้องกัน เพื่อช่วยให้ครูที่ปรึกษา นักจิตวิทยา หรือนักแนะแนวสามารถติดตามและช่วยเหลือผู้ที่มีแนวโน้มเสี่ยงต่อการฆ่าตัวตายได้อย่างทันทั่วถึง ผลการวิจัยนี้สามารถต่อยอดสู่การพัฒนา ระบบพยากรณ์ ความเสี่ยงอัตโนมัติ ในอนาคตเพื่อใช้เฝ้าระวังสุขภาพจิตของกลุ่มนักเรียน นักศึกษา และประชากรทั่วไปอย่างมีประสิทธิภาพมากขึ้น

7. ข้อเสนอแนะ

1. ผลลัพธ์จากแบบจำลองสามารถนำไปใช้พัฒนา “ระบบคัดกรองความเสี่ยงการฆ่าตัวตายอัตโนมัติ” เพื่อช่วยให้นักจิตวิทยา ครูแนะแนว หรือเจ้าหน้าที่สาธารณสุขสามารถติดตามกลุ่มเสี่ยงได้อย่างทันทั่วถึง
2. หน่วยงานด้านการศึกษาและสาธารณสุขควรนำผลการวิเคราะห์ไปใช้เป็นแนวทางเชิงป้องกัน (Preventive Approach) เพื่อออกแบบกิจกรรมเสริมสร้างสุขภาพจิตใจให้กับนักศึกษา

คำชี้แจงการใช้ AI

ในการจัดทำรายงานฉบับนี้ ผู้จัดทำได้ใช้เครื่องมือปัญญาประดิษฐ์ (Artificial Intelligence: AI) เพื่อช่วยในกระบวนการบางส่วน ได้แก่

1. การจัดรูปแบบข้อความ การตรวจสอบภาษา และการเรียบเรียงเนื้อหาให้มีความถูกต้องและอ่านเข้าใจง่าย
2. การช่วยวิเคราะห์และสรุปข้อมูลเบื้องต้นจากผลการทดลอง เช่น การอธิบายผลลัพธ์ของโมเดลการจำแนกประเภท
3. การจัดทำเอกสารประกอบ เช่น ส่วนบรรณานุกรม และรูปแบบการอ้างอิงให้เป็นไปตามมาตรฐานทางวิชาการ

ทั้งนี้ ผู้จัดทำได้ตรวจสอบและปรับปรุงเนื้อหาทั้งหมดด้วยตนเอง เพื่อให้ข้อมูลมีความถูกต้อง เหมาะสม และสอดคล้องกับวัตถุประสงค์ของงานวิจัย โดย AI ถูกใช้เป็นเพียงเครื่องมือสนับสนุนทางวิชาการเท่านั้น มิได้ใช้แทนการคิด วิเคราะห์ หรือสรุปผลของผู้วิจัย

การอ้างอิง

- [1] ศูนย์เฝ้าระวังป้องกันการฆ่าตัวตาย (สังกัดกรมสุขภาพจิต), “รายงานสถานการณ์การฆ่าตัวตายของประเทศไทยในปัจจุบัน 2566,” Available: <https://suicide.dmh.go.th/news/view.asp?id=92#>.
- [2] กรมสุขภาพจิต, “ปัญหาพฤติกรรมกรรมการฆ่าตัวตาย,” กรมสุขภาพจิต, 29 เมษายน 2563. [ออนไลน์]. Available: <https://dmh.go.th/news/view.asp?id=2287>.
- [3] T. Boonchob, “เข้าใจ CRISP-DM ฉบับเร่งรัด,” 20 กันยายน 2020. [ออนไลน์]. Available: kamboonchob.medium.com/เข้าใจ-crisp-dm-ฉบับเร่งรัด-b0913050198f
- [4] น. นฤชิตพิชัย, “โรงพยาบาลมณารมย์,” โรงพยาบาลมณารมย์, [ออนไลน์]. Available: https://www.manarom.com/blog/Suicide_prevention.html.
- [5] S. Alom, “Early Suicide Prediction Dataset,” [ออนไลน์]. Available: <https://www.kaggle.com/datasets/samulalom01/early-suicide-prediction/data>.
- [6] ด. สุขประเสริฐ, การทำเหมืองข้อมูลด้วยโปรแกรม RapidMiner Studio, 2567.
- [7] ธ. กิติธรรษาภรณ์, “Random Forest,” มกราคม 2563. [ออนไลน์]. Available: guopai.github.io/ml-blog10.html.
- [8] Wikipedia, “ความไวและความจำเพาะ,” 9 มกราคม 2568. [ออนไลน์]. Available: th.wikipedia.org/wiki/ความไวและความจำเพาะ.
- [9] K. M. Han, H. Y. Jung, H. Choi, M. Kim, S. H. Hong, C. Park และ Y. S. & Kim, “Prediction Models for Suicide Attempts among Adolescents Using Machine Learning Techniques,” *Clinical Psychopharmacology and Neuroscience*, p. 609–620, 2022.
- [10] J. Y. Ryu, S. J. Jang และ S. A. & Lee, “Machine learning prediction of suicidal ideation, planning, and attempt among Korean adults: A population-based study,” *BMC Psychiatry*, p. 1–11, 2022.
- [11] A. R. & S. R. P. E. G., “Machine learning-based prediction of suicidal ideation, plans, and attempts among school-going adolescents,” *Informatics in Medicine Unlocked*, p. 101676, 2025.
- [12] Wikipedia, “CRISP-DM Process Diagram,” ม.ป.ป.. [ออนไลน์]. Available: https://en.wikipedia.org/wiki/Cross-industry_standard_process_for_data_mining#/media/File:CRISP-DM_Process_Diagram.png.
- [13] S. Alom, “Early Suicide Prediction,” Kaggle, 2025. [ออนไลน์]. Available: <https://www.kaggle.com/datasets/samulalom01/early-suicide-prediction/data>.